

ANÁLISIS DE VENTAS ONLINE 2021



INFORME FINAL PRÁCTICA 1

SOG2 – 2S2026
Grupo 5

Índice

Resumen ejecutivo	1
Hallazgos principales.....	1
Alcance y limitaciones del análisis.....	2
Planificación del proyecto	3
¿Cómo se dividieron las tareas entre los miembros del equipo?	3
¿Qué herramientas y tecnologías se decidieron utilizar y por qué?	4
¿Cómo se establecieron los plazos para cada fase del proyecto?.....	6
Proceso de análisis.....	8
Preparación de datos	8
1. Carga del conjunto de datos	8
2. Normalización de nombres de columnas	8
3. Selección de variables relevantes	8
4. Conversión de tipos y limpieza de valores	9
5. Detección y eliminación de filas inválidas	9
6. Generación de tablas auxiliares	9
7. Guardado del CSV limpio	10
8. Preparación para la carga a base de datos.....	10
Diagrama de la base de datos	11
Metodología de visualización.....	12
Criterio general de selección.....	12
Origen de los datos graficados	12
Selección de cada visualización	13
1. Evolución mensual de las ventas: gráfico de líneas.....	13
2. Ventas por método de pago: gráfico de barras verticales.....	14
3. Ventas por navegador / canal: gráfico de barras horizontales	14
4. Distribución de ventas por boletín y vale: barras agrupadas	15

5.	Uso de boletines y vales por mes: barras agrupadas	16
6.	Ticket promedio por rango de edad: gráfico de barras verticales	16
7.	Método de pago por género: barras horizontales apiladas al 100 %	17
8.	Edad frente a total de la venta: gráfico de dispersión	17
9.	Boletín y vale frente al ticket: mapa de calor	18
10.	Distribución del total de la venta: histograma	19
11.	Total de la venta por rango de edad: diagrama de caja	19
12.	Composición del 63.9 % presencial: gráfico de cascada	20
	Decisiones de diseño transversales	21
	Visualizaciones descartadas	22
	Análisis exploratorio y de tendencias	23
	Análisis exploratorio	23
	1. Obtención de los datos	23
	2. Estadísticas básicas de las variables numéricas	23
	3. Distribución de las ventas	25
	Análisis de tendencia	30
	1. Meses con mayores y menores ventas	30
	2. Navegador más preferido y menos popular	31
	3. Ventas pagadas contra entrega o en efectivo	32
	4. Meses con mayor uso de boletines y vales	34
	Síntesis del bloque	36
	Limitaciones	36
	Resultados detallados	37
	Segmentación de clientes y análisis de correlación	40
	Segmentación de clientes	40
	1. Agrupación por edad	40
	2. Comportamiento de compra entre géneros	43
	3. Agrupación por boletín y vale	45

Análisis de correlación	47
1. Total de venta frente a edad de cliente	47
2. Género frente a método de pago	49
3. Boletines frente a vales	50
Síntesis del bloque	51
Limitaciones	52
Resultados detallados	53
Conclusiones	57
Recomendaciones	61
Acciones concretas propuestas	61
1. Dos acciones concretas Clave #1	61
2. Dos acciones concretas Clave #2	61
3. Dos acciones concretas Clave #3	61
4. Dos acciones concretas Clave #4	62
5. Dos acciones concretas Segmentación y correlación	63
Respuestas a preguntas de alcance	65
Anexo: código y reproducibilidad	70
Estructura del repositorio	70
1. Reproducción del análisis	71
2. Agente conversacional	71
3. Herramientas expuestas por el MCPServer	72

Resumen ejecutivo

Este informe analiza las 6,500 transacciones registradas por la empresa durante 2021, por un total de Q1,340,575.80, con el objeto de describir el comportamiento de compra de su clientela y orientar la expansión hacia la sucursal física. Los datos se cargaron en una base PostgreSQL en la nube y se consultaron mediante un servidor MCP que alimenta tanto este documento como un agente conversacional de IA.

Hallazgos principales

1. **La empresa ya no es un negocio digital.** El 54.2 % de las ventas del año (3,523 transacciones) se registró en la tienda física, y otras 633 ventas originadas en internet se pagaron en efectivo, es decir, contra entrega. Sumadas, el 63.9 % de las transacciones exigen presencia física de alguien que entregue producto o reciba dinero. El canal que se sigue tratando como proyecto nuevo ya sostiene dos tercios de la operación.
2. **El año es plano, con un bache en noviembre.** Las ventas mensuales oscilan entre 493 y 577 transacciones sin temporadas marcadas. La única anomalía es que noviembre resulta el peor mes del año inmediatamente antes de que diciembre sea el mejor, una diferencia de 84 transacciones entre meses consecutivos.
3. **Las variables demográficas no segmentan a esta clientela.** La correlación entre la edad y el gasto es de -0.0252 y explica el 0.064 % de la variación; el género y el método de pago resultan estadísticamente independientes. Entre el tramo etario que más gasta y el que menos median Q20.21, y entre hombres y mujeres, Q3.70. Segmentar campañas por edad o género no tiene respaldo en los datos.
4. **El boletín es la única palanca que mueve el gasto.** Los clientes suscritos gastan Q236.24 por compra frente a Q181.76 de los no suscritos: Q54.47 más, un 30 %. Siendo el 44.9 % de las transacciones, aportan el 51.5 % de la facturación. Ninguna otra variable del conjunto de datos separa clientes con esa claridad.
5. **El vale de descuento está mal dirigido.** Al controlar por suscripción, el vale resta 6.9 % de ticket cuando llega a un cliente no suscrito y suma 3.8 % cuando se entrega dentro del boletín. Las 443 compras del primer caso representan descuento entregado a cambio de una compra más pequeña.

Alcance y limitaciones del análisis

El conjunto de datos registra qué se pagó y por dónde entró la venta, pero no por qué: no incluye producto, costo, margen, estado final del pedido ni campañas activas. Además cada cliente aparece con una sola transacción, de modo que no existe historial y no puede calcularse recurrencia ni valor de vida. Todas las relaciones reportadas son asociaciones y ninguna prueba causalidad.

Planificación del proyecto

¿Cómo se dividieron las tareas entre los miembros del equipo?

El criterio de división no fue repartir los ocho puntos del alcance en partes iguales, sino cortar el proyecto por sus dependencias técnicas. El enunciado describe una cadena: sin datos limpios no hay base de datos, sin base de datos no hay consultas, sin consultas no hay servidor MCP, sin servidor no hay agente conversacional. Repartir por puntos habría dejado a varias personas bloqueadas esperando el trabajo de otra.

Se definieron entonces cinco bloques, cada uno con una frontera clara y un entregable propio:

	Integrante	Carné	Bloque	Puntos del alcance
1	Derek Francisco Orellana Ibáñez	202001151	Datos y base de datos	1, diagrama, proceso de análisis, 3 gráficas
2	Juan Esteban Chacón Trampe	202300431	MCPServer	3.3, código y pruebas
3	Daniel Andree Hernandez Flores	202300512	Agente conversacional (Google ADK)	3.3, validación 2 al 6
4	Fátima Florisel Cerezo Paredes	202300434	Análisis exploratorio y de tendencias	2, 3, metodología, 5 gráficas
5	Valery Pamela Alarcon Ramos	202300794	Segmentación, correlación e informe final	4, 5, 4 gráficas, consolidación del informe

Dos decisiones sobre el reparto:

1. **La interfaz entre bloques se acordó antes de escribir código.** El integrante 2 definió el contrato de respuesta del MCPServer al inicio, lo que permitió que el integrante 3 avanzara en el agente y la integrante 5 en el análisis sin esperar a que las doce herramientas estuvieran terminadas. El módulo quedó como fuente única de consultas:

los scripts de análisis lo importan en lugar de reescribir el SQL, de modo que el informe, el servidor y el agente devuelven por construcción las mismas cifras.

2. **El punto 6 se repartió entre tres personas y hubo que reajustarlo.** Se solicita un mínimo de siete gráficos diferentes. El reparto inicial asignó cinco a la integrante 4 (distribuciones y tendencias) y un mínimo de tres a la integrante 5 (segmentación y correlación), que aportó cuatro. Se encargaron entonces tres visualizaciones adicionales al integrante 1 (histograma, diagrama de caja y gráfico de cascada), cada una de un tipo aún no utilizado. El proyecto cierra con doce visualizaciones, y los tipos empleados son línea, barras verticales, barras horizontales, barras agrupadas, barras apiladas al 100 %, dispersión, mapa de calor, histograma, diagrama de caja y cascada. Como tres personas trabajaban sobre un mismo entregable visual, se fijaron por adelantado la paleta, el formato de etiquetas y el pie de fuente.
3. **La integrante 5 no redacta conclusión propia.** Se piden exactamente cuatro conclusiones clave y el equipo es de cinco personas. Se acordó que quien consolida el PDF asumiera a cambio la coherencia del documento completo: verificación de que las cifras citadas en las cuatro conclusiones coinciden con las que devuelve la base de datos, unificación de estilo y armado final.

¿Qué herramientas y tecnologías se decidieron utilizar y por qué?

Herramienta	Uso en el proyecto	Por qué se eligió
PostgreSQL (nube)	Base de datos relacional	Se eligió a PostgreSQL en lugar de MySQL por <code>percentile_cont</code> , <code>mode()</code> y <code>corr()</code> , que resuelven en el motor la mediana, la moda y la correlación de Pearson.
Python 3.10+	Limpieza, carga, análisis y gráficas	Cumple el requisito de lenguaje de análisis y es el único ecosistema donde conviven <code>psycopg2</code> , <code>matplotlib</code> y el SDK de MCP sin puentes entre lenguajes.

pandas	Limpieza y normalización del CSV	Resuelve en pocas líneas la normalización de nombres, la coerción de tipos y la detección de nulos y duplicados.
psycopg2	Conexión a PostgreSQL	Controlador estándar. Se usó <code>psycopg2.sql</code> para componer identificadores de forma segura y <code>RealDictCursor</code> para recibir filas como diccionarios.
matplotlib	Las nueve visualizaciones	Da control fino sobre la posición de cada etiqueta, que era necesario para cumplir el criterio de rotular todos los valores sin superposiciones.
MCP (Model Context Protocol)	Servidor de doce herramientas	Requisito explícito del enunciado. Se eligió <code>stdio</code> porque el agente levanta el servidor como subproceso y no hace falta exponer un puerto.
Google ADK + Gemini Flash-Lite	Agente conversacional	Requisito del enunciado; el propio documento recomienda las versiones Flash o Flash-Lite por velocidad y uso gratuito dentro de sus límites.
Git y GitHub	Control de versiones	Se trabajó con ramas por integrante (<code>feat/<carné>/<tema></code>) sobre <code>develop</code> .
Word	Informe final	La documentación se consolidó en la plataforma de Microsoft Word para su personalización y detallado.

Se tomaron dos decisiones técnicas por restricción:

1. El agente vive en un entorno virtual separado (`.venv.-agent`), porque `google-adk` requiere `mcp<2` mientras que el `MCPServer` usa `mcp 2.x`; aislar los entornos fue más barato que degradar el servidor.
2. El análisis estadístico se resolvió sin `SciPy`: los contrastes que necesitaba la significancia de Pearson sobre muestra grande y `chi-cuadrado` con uno y dos grados de libertad tienen

forma cerrada y se implementaron con math, evitando sumar una dependencia pesada al proyecto por tres fórmulas.

¿Cómo se establecieron los plazos para cada fase del proyecto?

Los plazos se derivaron de la cadena de dependencias. Cada fase se programó para terminar cuando la siguiente la necesitaba, y se fijó un punto de control al final de cada una: hasta que el bloque anterior no estuviera integrado en develop y verificado, el siguiente no arrancaba. El tiempo estimado por el enunciado es de 20 horas, que se distribuyeron en cinco fases sobre una semana.

Fase	Días	Responsable	Condición de cierre
0. Arranque y estructura	13 y 16 ago	Integrante 1	Repositorio, .env.example , estructura de carpetas y planificación acordada
1. Datos y base de datos	16 ago	Integrante 1	CSV limpio cargado en PostgreSQL y diagrama entregado
2. MCPServer	17 ago	Integrante 2	Las 12 herramientas responden con el contrato acordado
3. Agente y análisis exploratorio	17 ago	Integrantes 3 y 4	Agente responde los puntos 2 al 6; 5 gráficas generadas
4. Segmentación y correlación	18 y 19 ago	Integrante 5	Puntos 4 y 5 resueltos; 4 gráficas generadas
5. Consolidación del informe	24 ago	Integrante 5	PDF SOG2-2S26_grupo5.pdf armado y revisado

Las fases 2, 3 y 4 pudieron solaparse parcialmente gracias al contrato de respuesta acordado de antemano: mientras el integrante 2 terminaba las últimas herramientas, el 3 ya integraba el agente contra las primeras y la 5 trabajaba directamente sobre queries.py.

Un desfase real y cómo se manejó. Durante la fase 3 se detectó un error en la limpieza de datos que alteraba el total de ventas por mes. Corregirlo obligó a recargar la base y a regenerar las gráficas ya producidas. El costo fue bajo porque las gráficas se generan por script y ninguna se había editado a mano: bastó volver a ejecutar el análisis.

Se dejó deliberadamente la consolidación del PDF como última fase y con holgura, porque es la única que depende de que todos los bloques estén cerrados.

Proceso de análisis

Preparación de datos

1. Carga del conjunto de datos

Se inició con la lectura del archivo original `data/raw/Venta_online_c.csv` usando `pandas.read_csv()`. Este paso permitió validar la estructura inicial del dataset, confirmar el delimitador correcto y conocer la cantidad de filas y columnas disponibles antes de aplicar transformaciones.

2. Normalización de nombres de columnas

Se estandarizaron los nombres de las columnas para un formato uniforme y más fácil de manejar en Python y PostgreSQL. La estrategia consistió en:

- eliminar espacios y caracteres no deseados,
- convertir a minúsculas,
- reemplazar espacios o guiones por guiones bajos,
- homogeneizar nombres

Esto evitó errores de referencia al trabajar con el csv y facilitó la integración con la base de datos.

3. Selección de variables relevantes

Se identificaron únicamente las columnas necesarias para el análisis y la carga final a la base de datos. Se descartaron atributos no requeridos para el modelo de negocio y se consolidó el conjunto de campos clave:

- `Id_cliente`
- `edad`
- `genero`
- `n_compras`
- `venta_total`
- `fecha_compra`

-
- monto_compra
 - método_pago
 - tiempo
 - navegador
 - boletín
 - vale

Con esta selección se redujo ruido y se evitó trabajar con datos redundantes o sin valor analítico.

4. Conversión de tipos y limpieza de valores

Se aplicó una normalización de tipos para asegurar consistencia:

- edad, n_compras, venta_total, monto_compra, tiempo, boletín, vale se convirtieron a numéricos.
- fecha_compra se transformó a formato de fecha
- Variables categóricas como genero, metodo_pago y navegador se normalizaron a texto limpio, eliminando espacios y convirtiendo a minúsculas.

Esto fue clave para evitar inconsistencias como fechas mal formateadas.

5. Detección y eliminación de filas inválidas

- Se revisaron las columnas críticas y se eliminaron las filas que presentaban valores nulos o inconsistentes en campos indispensables.
- Se aplicó una validación sobre columnas esenciales del negocio y del modelo de datos.
- Se registró el número de filas descartadas, permitiendo conocer el impacto de la limpieza y asegurar que no se introdujeran registros corruptos a la base de datos.

6. Generación de tablas auxiliares

Para preparar el diseño de bases de datos relacional, se generaron tablas auxiliares a partir de los valores únicos de:

- género

-
- método de pago
 - navegador

Esto permite normalizar dimensiones y evitar la duplicación de valores categóricos en la tabla principal de ventas o clientes.

7. Guardado del CSV limpio

El resultado final se guardó en `data/processed/Venta_online_c_limpio.csv` con el mismo separador `;` y sin índice. Este archivo ya quedó listo para su carga a PostgreSQL, con una estructura limpia y consistente.

8. Preparación para la carga a base de datos

Adicionalmente, en la etapa de carga `db/carga.py` se reafirmó la validación del csv final:

- comprobación de columnas requeridas,
- coerción de tipos a enteros y fechas,
- eliminación de filas con valores no insertables,
- preparación de registros para cliente y venta en formato compatible con PostgreSQL.

Este enfoque garantizó que el archivo limpio pudiera cargarse de forma segura, evitando errores de integridad y facilitando la inserción masiva.

Diagrama de la base de datos




Diagrama entidad-relación de la base de datos

Metodología de visualización

Criterio general de selección

La elección de cada gráfico no partió del catálogo de tipos disponibles, sino de la pregunta de negocio que debía responder. Antes de escribir código se clasificó cada hallazgo del análisis exploratorio y de tendencias según su naturaleza estadística, y esa clasificación determinó la forma visual:

Naturaleza del hallazgo	Forma visual apropiada	Razón
Variable continua en el tiempo	Línea	La continuidad del trazo comunica que las observaciones están ordenadas y son comparables entre sí.
Comparación entre categorías excluyentes	Barras	La longitud es el atributo visual que el ojo compara con mayor precisión.
Categorías con etiquetas largas	Barras horizontales	Evita rotar el texto del eje, que reduce la legibilidad.
Dos series comparables sobre el mismo eje	Barras agrupadas	Permite comparar tanto entre categorías como entre series sin superponer información.

El principio rector fue que cada gráfico respondiera una sola pregunta de forma inequívoca. Cuando una visualización intentaba responder dos, se dividió en dos gráficos distintos.

Origen de los datos graficados

Todas las visualizaciones se construyeron a partir de consultas SQL ejecutadas directamente contra la base de datos PostgreSQL en la nube, no sobre el archivo .csv original. Esta decisión garantiza que las cifras del informe, las que devuelve el MCPServer y las que muestra el agente conversacional provengan de una misma fuente.

La agregación se delegó a PostgreSQL en lugar de resolverla en Python: el motor procesa la agregación sobre los índices existentes, y solo transporta el resultado, que son unas pocas decenas de filas.

El script análisis/exploratorio.py reutiliza las funciones del módulo `mcp_server/quieres.py` de modo que el informe y el agente conversacional comparten exactamente la misma lógica de consulta. Este bloque añadió dos consultas propias, que son las que el MCPServer no expone: el desglose mensual de boletines y vales y el cruce entre método de pago y canal de origen, necesario para separar el efectivo cobrado en caja del cobrado al momento de la entrega.

El bloque de segmentación y correlación sigue el mismo criterio en `análisis/segmentación.py`, que produce las visualizaciones 6 a 9 y comparte paleta, formato de etiquetas y pie de fuente con el script anterior, de modo que las doce gráficas se lean como un solo conjunto. Sus consultas propias son el desglose enriquecido por rango de edad y por género, el MCPServer entrega el ticket, pero no la penetración de boletín, vale y canal dentro de cada segmento, el par (edad, venta_total) sin agregar que alimenta el diagrama de dispersión y la correlación de Spearman, que `corr()` de PostgreSQL no calcula.

Selección de cada visualización

1. Evolución mensual de las ventas: gráfico de líneas

Pregunta: ¿cómo se comportaron las ventas a lo largo de 2021 y en qué meses alcanzaron su máximo y su mínimo? (puntos 2.c y 3.a)

Se eligió un gráfico de líneas porque el mes es una variable ordenada y continua: enero precede a febrero, y esa secuencia es parte del significado del dato. Un gráfico de barras habría representado los mismos valores, pero presentando los meses como categorías independientes, lo que oculta la forma de la tendencia.

Los doce puntos llevan su valor exacto anotado, y los dos meses extremos se resaltan además con color y con la palabra Máximo o Mínimo. Diciembre y noviembre son precisamente la

respuesta al punto 3.a, y el gráfico debía señalarlos sin exigir que el lector recorriera los doce puntos comparándolos.

La posición de cada etiqueta se calcula según la forma de la curva: en los valles se escribe debajo del punto, en los picos encima, y en los tramos ascendentes o descendentes se recuesta hacia el lado ya recorrido por la línea. Así ninguna cifra se encima con el trazo ni con las etiquetas vecinas.

El eje vertical no arranca en cero. Es una decisión deliberada: los totales mensuales se mueven en un rango estrecho y, forzando el origen en cero, la línea quedaría prácticamente plana y la variación real resultaría invisible. Como el gráfico describe una evolución y no compara magnitudes absolutas entre categorías, el recorte del eje es una convención aceptada para series de tiempo; además, al estar rotulados los doce valores, la lectura no depende en ningún momento de estimar la altura contra el eje.

2. Ventas por método de pago: gráfico de barras verticales

Pregunta: ¿cómo se reparten las ventas entre efectivo, crédito y débito? (puntos 2.c y 3.c)

Con solo tres categorías excluyentes y sin orden intrínseco entre ellas, las barras verticales son la forma más directa de comparación. Se ordenaron de mayor a menor frecuencia para que el ranking se lea sin esfuerzo, y se destacó la categoría dominante con un color más intenso.

Se descartó un gráfico circular. Aunque el reparto suma el 100 % y un pastel parecería natural, comparar ángulos es notablemente menos preciso que comparar longitudes, y la diferencia entre débito (22.6 %) y efectivo (18.6 %) se distingue peor en un círculo que en dos barras contiguas.

Cada barra se etiquetó con el conteo absoluto y el porcentaje: el porcentaje comunica el peso relativo y el absoluto permite dimensionar la muestra.

3. Ventas por navegador / canal: gráfico de barras horizontales

Pregunta: ¿cuál es el canal más preferido y cuál el menos popular? (puntos 2.c y 3.b)

Se mantuvieron las barras por tratarse de una comparación entre categorías, pero se giraron a horizontal por una razón práctica: las etiquetas son largas y en orientación vertical obligarían a rotar el texto en diagonal. En horizontal, cada nombre se lee de corrido junto a su barra.

La orientación además aporta una ventaja interpretativa: al ordenar de mayor a menor de arriba hacia abajo, el gráfico se lee como un ranking, que es exactamente lo que pide el punto 3.b.

Se coloreó Tienda Física de forma distinta al resto porque no es un navegador sino el canal presencial, y agrupar ambas cosas bajo un mismo color sugeriría una comparación entre iguales que no lo es. La distinción visual permite responder dos preguntas en un solo gráfico sin confundirlas: el canal más usado en términos absolutos es la tienda física (3,523 ventas, 54.2 %), mientras que entre los navegadores propiamente dichos el preferido es el Navegador 1 (1,273 ventas) y el menos popular el Navegador 4 (197 ventas).

Se graficó la cantidad de ventas y no el monto acumulado porque la pregunta es de preferencia de canal, y la preferencia se expresa en número de transacciones, no en dinero.

4. Distribución de ventas por boletín y vale: barras agrupadas

Pregunta: ¿qué proporción de las ventas involucró boletín y qué proporción involucró vale? (punto 2.c)

El punto 2.c enumera cinco distribuciones que deben visualizarse, y boletín y vale son dos de ellas. Como ambas son variables binarias del mismo tipo —cada una divide las ventas en «sí la usó» y «no la usó»— se resolvieron en un solo gráfico de barras agrupadas en lugar de dos gráficos separados: compartir el eje vertical permite comparar directamente la penetración de un instrumento frente al otro, que es el hallazgo relevante.

Se optó por representar ambas categorías (sí y no) y no únicamente los casos positivos, porque una distribución solo se comprende cuando se ve contra su complemento: 2,921 ventas con boletín solo significan algo al lado de las 3,579 sin él.

La lectura resultante es contundente: el boletín alcanza al 44.9 % de las ventas mientras que el vale apenas llega al 19.3 %, es decir, el boletín tiene más del doble de penetración que el vale.

5. Uso de boletines y vales por mes: barras agrupadas

Pregunta: ¿en qué meses se usaron más boletines y vales? (punto 3.d)

Este hallazgo involucra dos series (boletines y vales) sobre un mismo eje temporal de doce meses. Se optó por barras agrupadas en lugar de barras apiladas porque boletín y vale no son categorías excluyentes: una misma venta puede registrar ambos, de modo que apilarlas sumaría casos duplicados y produciría una altura sin significado. Agrupadas, cada barra conserva su propia línea base y ambas magnitudes se comparan contra el eje y entre sí.

Tampoco se usó un gráfico de líneas, pese al eje temporal, porque aquí el interés no está en la forma de la tendencia sino en identificar meses puntuales de mayor uso; las barras individualizan cada mes y facilitan esa lectura.

La diferencia de escala entre ambas series se conserva a propósito: que los boletines dupliquen consistentemente a los vales es en sí mismo un hallazgo sobre la penetración de cada instrumento comercial.

6. Ticket promedio por rango de edad: gráfico de barras verticales

Pregunta: ¿gastan distinto los clientes según su edad? (punto 4.a)

Se graficó el ticket promedio y no la facturación total del tramo. Es una distinción que cambia por completo la pregunta que responde el gráfico: la facturación total seguiría el tamaño de cada segmento y mostraría, trivialmente, que los tramos con más clientes venden más. El ticket promedio normaliza por tamaño y permite comparar comportamiento, que es lo que pide el punto.

Aquí el eje vertical sí arranca en cero, al contrario que en la evolución mensual. La diferencia de criterio es deliberada: este gráfico compara magnitudes entre categorías independientes, y recortar la base convertiría una brecha real de Q20.21 en una montaña visual que sugeriría un hallazgo inexistente. Que las cinco barras se vean casi iguales es el hallazgo.

Se añadió una línea horizontal punteada con el promedio general (Q206.24) como referencia: sin ella, el lector no tendría contra qué juzgar si un tramo está alto o bajo. Las cifras se rotularon

dentro de cada barra y no encima, porque a la altura del extremo superior de las barras pasa justamente esa línea de referencia y las etiquetas se encimarían con ella. Se destacaron en verde el tramo de mayor ticket y en rojo el de menor, siguiendo la misma convención de color del resto del informe.

7. Método de pago por género: barras horizontales apiladas al 100 %

Pregunta: ¿pagan distinto hombres y mujeres? (puntos 4.b y 5.b)

Los dos géneros tienen distinto número de compras (3,372 y 3,128), de modo que comparar cantidades absolutas induciría a error: el grupo más grande mostraría barras más largas en todos los métodos sin que eso signifique preferencia. Al normalizar cada género al 100 % de sus propias compras, ambos grupos se vuelven directamente comparables.

Se eligieron barras apiladas y no agrupadas porque aquí las categorías sí son excluyentes —cada venta tiene un único método de pago— y su suma tiene significado: el 100 % de las compras del género. Es exactamente el caso contrario al de boletín y vale, donde una misma venta puede registrar ambos y por eso allí se usaron barras agrupadas.

La orientación horizontal permite leer las dos franjas una encima de la otra, que es la comparación que interesa. El resultado es un gráfico visualmente monótono, y esa monotonía es el mensaje: la mayor brecha entre ambos géneros es de 2.2 puntos porcentuales. Un gráfico que muestra una no-diferencia debe verse como una no-diferencia.

8. Edad frente a total de la venta: gráfico de dispersión

Pregunta: ¿existe relación entre la edad del cliente y lo que gasta? (punto 5.a)

Es el único gráfico del informe donde se representan las 6,500 observaciones individuales sin agregar. La dispersión es la forma canónica para dos variables continuas y la única que permite ver la estructura de la relación en lugar de su resumen: un coeficiente de -0.0252 es un número que hay que creer, mientras que una nube sin forma es una evidencia que se verifica de un vistazo.

Con 6,500 puntos en un rango de 62 edades el solapamiento es inevitable, así que se aplicó transparencia (alfa 0.28) y se redujo el tamaño del marcador: la densidad de la banda inferior pasa a codificar cuántas ventas se concentran en montos bajos, lo que aporta información en vez de estorbar. Se añadió la recta de regresión — cuya pendiente de $-Q0.48$ por año se traduce en una línea visualmente plana— y una línea punteada con la venta promedio.

Se decidió no recortar los valores atípicos pese a que las ventas por encima de Q1,500 estiran el eje y comprimen la nube principal. Eliminarlas habría producido un gráfico más bonito y menos honesto: esas ventas existen, y su dispersión a lo largo de todas las edades refuerza precisamente la conclusión de que la edad no predice el gasto.

El recuadro con el coeficiente, el r^2 y la lectura («sin relación aprovechable») se incluyó dentro del área del gráfico para que la imagen sea autosuficiente al extraerla del informe.

9. Boletín y vale frente al ticket: mapa de calor

Pregunta: ¿cuál de los dos instrumentos comerciales mueve el gasto? (puntos 4.c y 5.c)

El cruce de dos variables binarias produce exactamente cuatro celdas, y la pregunta no es cuánto vale cada una por separado sino en qué dirección se produce la separación. Un mapa de calor codifica el ticket promedio en intensidad de color y permite responder eso de inmediato: las dos celdas superiores son oscuras y las dos inferiores claras, es decir, la variación ocurre entre filas boletín y no entre columnas vale.

Se descartaron barras agrupadas para las cuatro combinaciones. Habrían mostrado los mismos cuatro valores con mayor precisión de lectura, pero como una lista de cuatro categorías sueltas; el hecho de que se trata de una matriz de 2×2 y de que una dimensión domina sobre la otra se habría perdido. Es el caso en que la estructura del dato importa más que la precisión de la comparación, y por eso se aceptó el intercambio.

Para compensar la conocida imprecisión del color como canal cuantitativo, cada celda lleva rotulado su ticket exacto y su número de compras, y se incluyó la barra de color con escala en quetzales. El color del texto se calcula según la intensidad del fondo para mantener el contraste

legible en las cuatro celdas. Las líneas blancas de separación se agregaron para que las celdas se lean como categorías discretas y no como un gradiente continuo.

10. Distribución del total de la venta: histograma

Pregunta: ¿cómo se reparten las ventas a lo largo de la escala de montos? (punto 2.b)

Las medidas de tendencia central del punto 2.b se reportaban únicamente como tabla, y una tabla no permite ver la forma de una distribución. El histograma es la única representación que muestra dónde se acumulan los casos, y aquí ese reparto es el hallazgo: la media de Q206.24 supera a la mediana de Q137.35 en un 50 %, señal de una asimetría hacia la derecha que ninguna de las tres medidas comunica por sí sola. Se eligió una amplitud de clase de Q50 tras comparar alternativas. Intervalos más anchos borraban el escalón entre la clase modal (Q50-100, con 1,442 ventas) y sus vecinas; más estrechos fragmentaban la cola en barras de altura irrelevante y añadían ruido sin información. La decisión de diseño con más consecuencias fue truncar el eje en Q800 y agrupar la cola en una clase abierta. El máximo observado es de Q3,169, de modo que un eje completo dedicaría más de tres cuartas partes del ancho a barras casi invisibles y comprimiría contra el margen izquierdo la zona donde se concentra el 97.5 % de los casos. La clase agrupada se rotuló «800+», se dibujó con trama diagonal para que no se confunda con una clase regular de Q50 y lleva anotado su conteo exacto de 161 ventas. Es un recorte que se declara en el propio gráfico, no una omisión silenciosa. El color codifica la posición respecto de la media: las clases que quedan por debajo van en tono claro, las que quedan por encima en tono oscuro, y la clase que contiene la media se marca en gris por ser la única ambigua. Así el 66.4 % de ventas que no alcanza el promedio se lee como una superficie y no como un dato suelto. Media y mediana se trazaron como líneas verticales rotuladas, y la distancia entre ambas se anotó explícitamente, porque esa separación es justamente lo que el gráfico demuestra.

11. Total de la venta por rango de edad: diagrama de caja

Pregunta: ¿la edad separa a los clientes por su gasto, más allá del promedio? (puntos 4.a y 5.a)

La visualización 6 ya compara el ticket promedio entre rangos de edad, pero un promedio admite una objeción razonable: puede ocultar distribuciones muy distintas. Dos grupos con la misma media pueden tener dispersiones opuestas. El diagrama de caja es la respuesta directa a esa objeción, porque muestra simultáneamente mediana, cuartiles y recorrido de cada segmento. Se escogió frente a un gráfico de violín o a histogramas superpuestos por una razón de lectura: con cinco categorías, las cajas alineadas permiten comparar posición y amplitud de un vistazo, mientras que cinco densidades superpuestas exigirían al lector distinguir curvas que aquí serían casi idénticas. Y la coincidencia es precisamente el mensaje. Igual que en el histograma, el eje vertical se recortó —en Q700— porque los valores atípicos llegan a Q3,169 y con el eje completo las cinco cajas quedarían aplastadas contra la base, anulando la comparación que da sentido al gráfico. Por el mismo motivo se omitieron los puntos atípicos individuales: el objeto de esta visualización es el cuerpo central de cada distribución, no sus extremos, que ya quedan cubiertos por el histograma anterior. Cada caja lleva rotulados sus tres cuartiles y, bajo el eje, el tamaño de su muestra, dato necesario para juzgar la estabilidad del tramo 56+ (346 clientes). Una línea horizontal con la mediana general sirve de referencia común, y el recuadro superior enuncia la conclusión que la imagen sostiene: las cinco distribuciones se solapan y solo Q21.55 separan a la mediana más alta de la más baja.

12. Composición del 63.9 % presencial: gráfico de cascada

Pregunta: ¿de dónde sale la cifra de ventas que exigen presencia física? (punto 3.c)

Este hallazgo no proviene de una columna sino de un cruce entre dos: canal de origen y método de pago. Presentarlo como un total aislado obligaba al lector a aceptar el 63.9 % por confianza. La cascada existe justamente para eso: hace visible la aritmética de un agregado, mostrando cómo cada componente se suma hasta el subtotal. Se descartó un gráfico circular, que habría mostrado las tres porciones pero no la operación que las combina, y unas barras apiladas simples, que habrían dado la suma sin distinguir el subtotal intermedio de sus sumandos. La cascada conserva ambas cosas: las dos primeras barras flotan sobre la base acumulada, la tercera reinicia en cero para señalar que es un subtotal, y la cuarta completa hasta el total del

año. El color separa las funciones en lugar de decorar: azul oscuro para el canal presencial, rojo para el componente inferido —las 633 ventas en línea pagadas en efectivo, que es el dato que exige un supuesto—, verde para el subtotal y azul claro para el remanente puramente digital. Las líneas punteadas de conexión entre barras marcan la continuidad del acumulado, y una línea de referencia con el total de 6,500 ventas cierra la escala. Cada barra lleva su valor absoluto y su porcentaje, y el recuadro enuncia el resultado en lenguaje llano. La visualización tiene además un valor de trazabilidad: al mostrar la cifra descompuesta, deja a la vista que 633 de las 4,156 transacciones dependen de una inferencia y no de un campo registrado, tal como se advierte en el punto 3.c.

Decisiones de diseño transversales

Se aplicaron los mismos criterios a las doce visualizaciones para que el informe se lea como un conjunto coherente:

- Paleta constante. Un azul institucional para la serie principal, verde para los valores destacados en positivo y rojo para los mínimos. El color se usa siempre para codificar significado, nunca como adorno.
- Todo valor rotulado sobre el dato. Sin excepción, cada barra y cada punto de las doce visualizaciones muestra su cifra exacta junto al elemento que la representa, y en las distribuciones se añade el porcentaje sobre el total. El criterio es que ninguna conclusión dependa de que el lector estime una altura o una longitud contra el eje: el gráfico debe entregar el dato, no insinuarlo.
- Ejes siempre identificados. Los doce gráficos rotulan ambos ejes con la magnitud y su unidad («Total de ventas (quetzales)», «Cantidad de ventas», «Mes»), y las series de las barras agrupadas se distinguen con leyenda.
- Eliminación de elementos no informativos. Se retiraron los bordes superior y derecho, y las rejillas se dejaron punteadas y tenues, de modo que el dato domine visualmente sobre la estructura del gráfico.

-
- Exportación a 150 ppp con recorte ajustado, resolución suficiente para que el texto se lea con nitidez al incorporar las imágenes al PDF final.
 - Reproducibilidad. Las gráficas no se editaron a mano: se regeneran por completo ejecutando `Python-analisis/exploratorio.py`, de forma que cualquier corrección en los datos se refleja en las imágenes sin trabajo manual.

Visualizaciones descartadas

Se evaluaron y descartaron tres alternativas, por las razones siguientes:

- Gráfico circular para el método de pago. La comparación de ángulos es menos precisa que la de longitudes; se prefirieron barras.
- Barras apiladas para boletín y vale. Las dos categorías no son excluyentes, por lo que el total apilado carecería de interpretación.
- Gráfico de violín para el gasto por rango de edad. Habría mostrado la densidad completa de cada segmento, pero con cinco distribuciones casi idénticas obligaría a distinguir curvas superpuestas; el diagrama de caja comunica la misma coincidencia con una lectura más directa.
- Barras apiladas simples para el 63.9 % presencial. Entregan la suma pero no distinguen el subtotal intermedio de sus componentes, que es justamente lo que la cascada hace visible.

Un caso merece mención aparte porque la decisión cambió durante el proyecto. El histograma de montos de venta se descartó en la primera ronda, con el argumento de que las medidas de tendencia central ya cubrían el punto 2.b. Al redactar el informe quedó claro que ese argumento era insuficiente: la media y la mediana señalan que existe asimetría, pero no permiten ver su magnitud ni dónde se acumulan las ventas, y sin esa imagen el lector no tiene forma de juzgar si el ticket promedio describe bien al negocio. El histograma se incorporó entonces como visualización 10 y es hoy el único gráfico que muestra la forma de la variable principal del conjunto de datos.

Análisis exploratorio y de tendencias

Análisis exploratorio


1. Obtención de los datos

Los datos se leyeron de la base PostgreSQL en la nube. La agregación se delegó al motor mediante group by, sum, count y avg, de modo que solo viajan a Python unas pocas decenas de filas ya resumidas.

El universo analizado son 6,500 transacciones del año 2021, por un total facturado de Q1,340,575.80.

2. Estadísticas básicas de las variables numéricas

Variable	Media	Mediana	Moda
edad	36.31	36.00	18.00
venta_total	206.24	137.35	98.00
num_compra	5.09	4.00	2.00
monto_compra	39.79	35.77	28.32
tiempo	767.38	768.00	852.00



Distribución del total de la venta

La distribución del gasto está fuertemente sesgada a la derecha. La media de Q206.24 pero la mediana es Q137.35: la media supera a la mediana en un 50 %. Eso significa que la mitad de las ventas del año no llegó a Q137.35 y que el promedio está siendo empujado hacia arriba por una minoría de transacciones grandes. Es un detalle con consecuencias prácticas, porque hablar del ticket promedio de Q206 describe mal a la venta típica del negocio. Cada vez que en este informe se compara un ticket promedio entre dos grupos, conviene recordar que se está comparando una media sobre una distribución asimétrica; por eso en el bloque de segmentación se reportan también las medianas. El histograma pone cifra a esa asimetría. 4,315 ventas, el 66.4 % del año, quedan por debajo de la media, de modo que el promedio es un valor que dos de cada tres transacciones no alcanzan. La clase más frecuente es la de Q50 a Q100, con 1,442 ventas, muy por debajo de la media, y a partir de ahí las frecuencias descienden de forma sostenida sin volver a repuntar. Las 161 ventas de Q800 o más, agrupadas en la última clase del gráfico, representan apenas el 2.5 % de las transacciones y son las que arrastran el promedio hacia arriba. De aquí se desprende una recomendación de lectura para el resto del

informe: cuando se requiera un valor que represente a la venta corriente conviene mirar la mediana, y reservar la media para los cálculos de facturación total, donde sí corresponde ponderar por monto.


La edad se reparte de forma amplia y centrada. Media de 36.31 años y mediana de 36.00 prácticamente coinciden, señal de una distribución simétrica sin sesgo. La moda de 18 años no debe leerse como que el cliente típico tenga 18: es simplemente el extremo inferior del rango observado y, con edades enteras entre 18 y 79, cualquier valor puntual acumula pocos casos.

La columna tiempo quedó fuera del análisis. Sus valores se concentran alrededor de 768 con una dispersión muy baja, pero ni el enunciado ni ningún diccionario de datos declaran en qué unidad están expresados. Sin esa referencia, el mismo número admite lecturas que llevarían a conclusiones opuestas, y no existe forma de decidir entre ellas a partir de la propia columna. Sus estadísticos se reportan por completitud, sin construir ningún hallazgo sobre ella. La respuesta 8.d recoge este vacío como recomendación.

3. Distribución de las ventas

Se solicitaba visualizar cinco distribuciones: por mes, método de pago, navegador, boletín y vale.

Por mes



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Evolución mensual de las ventas


Mes	Ventas	Total	Promedio
Enero	520	Q106,059.70	Q203.96
Febrero	545	Q108,962.10	Q199.93
Marzo	569	Q116,168.00	Q204.16
Abril	557	Q116,737.70	Q209.58
Mayo	530	Q112,533.80	Q212.33
Junio	543	Q112,153.90	Q206.54
Julio	565	Q113,645.10	Q201.14
Agosto	530	Q105,665.00	Q199.37
Septiembre	508	Q109,666.70	Q215.88
Octubre	563	Q115,559.60	Q205.26
Noviembre	493	Q99,385.50	Q201.59
Diciembre	577	Q124,038.70	Q214.97

La serie mensual presenta muy poca dispersión. El coeficiente de variación es del 4.6 % para el número de transacciones y del 5.5 % para el monto facturado, valores que sitúan a los doce meses dentro de una banda estrecha alrededor de su promedio de 542 transacciones. Los extremos quedan a un 9.0 % por debajo y un 6.5% por encima de esa media.

Descomponer el ingreso mensual en sus dos factores aclara de dónde procede lo poco que varía. El ticket promedio resulta ser la más estable de las tres series, con un coeficiente de variación de apenas 2.67 % y un recorrido total de Q16.51 entre agosto y septiembre. Dicho de otro modo, lo que gasta un cliente se mantiene prácticamente invariable durante todo el año, y las diferencias de ingreso entre un mes y otro dependen casi por completo de cuántas transacciones hubo, no de cuánto valió cada una. Esta descomposición tiene una consecuencia

operativa útil: permite seguir el desempeño mensual contando transacciones, sin necesidad de corregir por valor.

Por método de pago




Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Distribución de ventas por método de pago

Método	Ventas	%	Total	Promedio
Tarjeta de crédito	3,827	58.9 %	Q786,772.50	Q205.58
Tarjeta de débito	1,466	22.6 %	Q309,301.80	Q210.98
Efectivo	1,207	18.6 %	Q244,501.50	Q202.57

La tarjeta de crédito domina con casi seis de cada diez ventas. Lo llamativo no es el reparto sino la última columna: los tres tickets promedio caben en un rango de Q8.41, un 4.2 %. El método de pago dice mucho sobre cómo cobra la empresa y casi nada sobre cuánto gasta el cliente.

Por navegador o canal



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Distribución de ventas por navegador o canal


Canal	Ventas	%	Total	Promedio
Tienda física	3,523	54.2 %	Q719,298.50	Q204.17
Navegador 1	1,273	19.6 %	Q276,221.80	Q216.98
Navegador 2	847	13.0 %	Q175,415.60	Q207.10
Navegador 3	660	10.2 %	Q132,472.20	Q200.72
Navegador 4	197	3.0 %	Q37,167.70	Q188.67

Aquí aparece el primer hallazgo estructural del informe: la tienda física concentra el 54.2 % de las transacciones del año, frente al 45.8 % que reparten entre sí los cuatro navegadores con 2,977 ventas. El enunciado presenta el punto de venta presencial como la expansión reciente de un negocio nacido en línea, pero los registros de 2021 lo muestran ya como el canal mayoritario durante los doce meses del ejercicio.

Dentro de lo digital la concentración es alta: sobre esas 2,977 ventas en línea, el Navegador 1 acumula el 42.8 % y el Navegador 4 no llega al 7 %. Una relación de más de seis a uno entre el primero y el último del ranking.

El ticket sí varía algo más entre canales que entre métodos de pago: del Q216.98 del Navegador 1 al Q188.67 del Navegador 4 hay Q28.31 de diferencia. Conviene no sobreinterpretarlo, porque el Navegador 4 tiene la base más pequeña de la tabla y sus promedios son los menos estables.

Por boletín y vale



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Distribución de ventas por boletín y vale

Boletín	Vale	Ventas	%	Ticket promedio
No	No	3,136	48.2 %	Q183.33
No	Sí	443	6.8 %	Q170.66
Sí	No	2,110	32.5 %	Q233.80
Sí	Sí	811	12.5 %	Q242.57

Agregando cada instrumento por separado, el boletín aparece en 2,921 ventas (44.9 %) y el vale en 1,254 (19.3 %), una proporción de 2.3 a 1 a favor del primero.

La columna del ticket confirma que las dos filas con boletín se despegan claramente de las dos sin él, mientras que el vale por sí solo no ordena nada.

Análisis de tendencia

1. Meses con mayores y menores ventas

	Mes	Ventas	Facturación
Mayores ventas	Diciembre	577	Q124,038.70
Menores ventas	Noviembre	493	Q99,385.50

Los dos criterios posibles: cantidad de transacciones y monto facturado. Señalan el mismo par de meses, de modo que la respuesta no depende de cuál se adopte. Conviene comprobarlo antes de afirmarlo, porque no tenía por qué ocurrir: un mes de muchas ventas pequeñas podría facturar menos que otro de pocas ventas grandes. Que ambos ordenamientos coincidan se explica por la estabilidad del ticket.

Medidos contra el promedio anual, diciembre se ubica un 6.5 % por encima y noviembre un 9% por debajo. La distancia entre ambos es de 84 transacciones y Q24,653.20, la mayor que separa a dos meses cualesquiera del ejercicio.

Un rasgo del calendario merece registrarse porque una tabla ordenada por volumen no lo deja ver: los dos meses extremos del año son consecutivos. Su lectura comercial y la acción que se deriva de ella corresponden a la conclusión clave 4 y a su primera recomendación.

2. Navegador más preferido y menos popular

	Canal	Ventas	%
Canal más usado en general	Tienda física	3,523	54.2 %
Navegador más preferido	Navegador 1	1,273	19.6 %
Navegador menos popular	Navegador 4	197	3.0 %

El registro de canal mezcla dos naturalezas distintas: cuatro navegadores web y un punto de venta presencial. La tienda física encabeza el conteo total, pero incluirla en un ranking de navegadores respondería una pregunta que el enunciado no formula. Restringiendo la comparación a lo que sí son navegadores, el primero es el Navegador 1 y el último el Navegador 4, con una razón de 6.5 a 1 entre ambos extremos.

Sobre el fondo de esa cifra hay que ser prudente. La codificación del canal es puramente ordinal y no revela de qué producto se trata en cada caso. Un volumen bajo admite al menos dos explicaciones incompatibles entre sí: poca base de usuarios, o una base normal con fricción en algún paso del proceso de compra. Elegir entre ambas requiere información que el conjunto de datos no contiene, así que este punto se responde con el ranking y se detiene ahí. La respuesta 8.d recoge el dato faltante que permitiría resolverlo.

3. Ventas pagadas contra entrega o en efectivo

Concepto	Valor
Ventas contra entrega o en efectivo	1,207 de 6,500 (18.6 %)
Monto acumulado	Q244,501.50 de Q1,340,575.80 (18.2 %)


El resultado del punto es, entonces, 1,207 transacciones: el 18.6 % del volumen anual y el 18.2% del monto. Que ambos porcentajes casi coincidan indica que las ventas en efectivo no son sistemáticamente mayores ni menores que el resto; su ticket promedio es de Q202.57 contra los Q206.24 generales.

A ese total se le añadió un desglose que ninguna columna entrega por sí sola y que exigió cruzar el método de pago con el canal de origen:

Origen	Ventas	% del efectivo	Monto
Navegador (cobro en la entrega)	633	52.4 %	Q129,138.10
Tienda física (cobro en caja)	574	47.6 %	Q115,363.40

La partición se apoya en una regla única: si una compra se originó en un navegador y se liquidó en efectivo, el dinero no pudo ingresar por caja, y la única vía operativa para recibirlo es el domicilio del comprador en el momento de la entrega. Bajo ese criterio, 633 transacciones, el 21.3 % de las ventas en línea, constituyen pago contra entrega en sentido estricto, mientras que las 574 restantes son cobro presencial.


Corresponde marcar con precisión dónde termina el dato y dónde empieza la inferencia, porque capítulos posteriores se apoyan en ambos. El conteo de 1,207 proviene sin intermediación del campo MetodoPago y es verificable en la base. El reparto 633/574, en cambio, se deduce del canal de origen y descansa en el supuesto de que el efectivo no se cobra a distancia: es razonable y difícil de sostener de otro modo, pero sigue siendo un supuesto.



Composición del 63.9% presencial

El gráfico de cascada muestra la aritmética completa de ese hallazgo, que de otro modo habría que aceptar como un total ya calculado. A las 3,523 ventas de tienda física se suman las 633 en línea cobradas en la entrega, y ambas conforman 4,156 transacciones, el 63.9 % del año, que requieren que alguien entregue el producto o reciba el dinero en persona. El remanente, 2,344 ventas pagadas con tarjeta desde un navegador, es el 36.1 % que se resuelve por completo sin intervención presencial. La descomposición deja a la vista algo que el porcentaje agregado esconde: de esas 4,156 transacciones, 3,523 son dato directo del campo de canal y solo 633 dependen del supuesto descrito arriba. Aun descartando por completo el componente inferido, la tienda física por sí sola ya supera la mitad del año.

4. Meses con mayor uso de boletines y vales



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Uso de boletines y vales por mes

Mes	Ventas	Boletines	%	Vales	%
Enero	520	241	46.3 %	100	19.2 %
Febrero	545	259	47.5 %	91	16.7 %
Marzo	569	261	45.9 %	133	23.4 %
Abril	557	239	42.9 %	88	15.8 %
Mayo	530	251	47.4 %	97	18.3 %
Junio	543	228	42.0 %	102	18.8 %
Julio	565	236	41.8 %	96	17.0 %
Agosto	530	251	47.4 %	102	19.2 %
Septiembre	508	200	39.4 %	120	23.6 %
Octubre	563	260	46.2 %	85	15.1 %

Noviembre	493	233	47.3 %	112	22.7 %
Diciembre	577	262	45.4 %	128	22.2 %

La respuesta al punto es diciembre para los boletines, con 262 compras asociadas, y marzo para los vales, con 133.

Los dos máximos no tienen la misma solidez, y omitirlo daría una falsa sensación de precisión. El de los vales es nítido: marzo (133) supera al segundo, diciembre (128), por cinco compras, y al tercero, septiembre (120), por trece. El de los boletines es un empate técnico: diciembre registra 262, marzo 261 y octubre 260. Tres unidades separan al primero del tercero sobre bases mensuales superiores a las quinientas ventas, de manera que designar a diciembre como el mes de mayor uso de boletines es correcto pero frágil, y una variación mínima en los datos reordenaría el podio. La respuesta se entrega tal como la arroja el cálculo, con esta advertencia al lado.

Calculada sobre las doce parejas mensuales, la correlación entre ambas series es de -0.077 , indistinguible de cero. Los meses que mejor lo ilustran son estos:

Mes	Tasa de boletín	Tasa de vale
Septiembre	39.4 % — mínima del año	23.6 % — máxima del año
Octubre	46.2 % — por encima del promedio	15.1 % — mínima del año
Noviembre	47.3 % — de las más altas	22.7 % — de las más altas

Cada uno combina los dos indicadores de una forma distinta, sin que un valor alto en una columna anticipe nada sobre la otra. Noviembre añade un contraste propio: reúne una de las coberturas de boletín más altas del ejercicio y es, al mismo tiempo, el mes de menor volumen de ventas.

Síntesis del bloque

Hallazgo	Cifra
La operación es mayoritariamente presencial	63.9 % de las ventas requieren presencia física
El año no tiene estacionalidad	493 a 577 ventas por mes, promedio 542
Noviembre es el bache justo antes del pico	84 transacciones menos que diciembre
Boletín y vale se mueven descoordinados	correlación mensual de -0.077

A esto se suma un resultado en negativo: ni el método de pago ni el mes explican diferencias relevantes de gasto. Los tickets promedio se mantienen entre Q199 y Q216 se mire por donde se mire. La única variable que sí separa clientes por gasto aparece en el bloque siguiente, y es la suscripción al boletín.

Limitaciones

1. **Un único ejercicio observado.** Toda la descripción se apoya en 2021. Sin años anteriores ni posteriores no hay forma de distinguir una pauta recurrente de una particularidad de ese ejercicio, por lo que las regularidades mensuales se reportan como observadas y no como estacionales.
2. **Faltan las variables explicativas.** No se registran campañas activas, inversión publicitaria ni costos por canal. El bloque puede establecer qué ocurrió, pero no atribuirlo a una causa identificable.
3. **La columna tiempo carece de unidad declarada.** Quedó excluida de toda interpretación, con la pérdida de una variable completa del conjunto.

4. **La codificación del canal es ordinal y opaca.** Los identificadores del 1 al 4 no informan de qué navegador, dispositivo o aplicación se trata, lo que impide diagnosticar la causa de un volumen bajo.
5. **El desglose del efectivo es inferido, no medido.** El conteo total de pagos en efectivo se verifica directamente en la base; su partición entre cobro en caja y cobro a domicilio se deduce del canal de origen, porque ningún campo la registra.
6. **Sin producto ni costo no cabe hablar de rentabilidad.** El bloque completo se construye sobre ingresos, lo que obliga a dar por sentado que vender más siempre es preferible.

Resultados detallados

Salida completa de las consultas ejecutadas contra PostgreSQL. Incluye las estadísticas básicas, las cuatro distribuciones y los cuatro hallazgos de tendencias.

Salida de análisis/exploratorio.py

Análisis exploratorio y de tendencias · ventas 2021

2.b ESTADÍSTICAS BÁSICAS DE LAS VARIABLES NUMÉRICAS

Variable	Media	Mediana	Moda
edad	36.31	36.00	18.00
venta_total	206.24	137.35	98.00
num_compra	5.09	4.00	2.00
monto_compra	39.79	35.77	28.32
tiempo	767.38	768.00	852.00

2.c DISTRIBUCIÓN DE VENTAS POR MES (2021)

Mes	Ventas	Total	Promedio
Enero	520	Q106,059.70	Q203.96
Febrero	545	Q108,962.10	Q199.93
Marzo	569	Q116,168.00	Q204.16
Abril	557	Q116,737.70	Q209.58
Mayo	530	Q112,533.80	Q212.33
Junio	543	Q112,153.90	Q206.54
Julio	565	Q113,645.10	Q201.14

Agosto	530	Q105,665.00	Q199.37
Septiembre	508	Q109,666.70	Q215.88
Octubre	563	Q115,559.60	Q205.26
Noviembre	493	Q99,385.50	Q201.59
Diciembre	577	Q124,038.70	Q214.97

2.c DISTRIBUCIÓN DE VENTAS POR MÉTODO DE PAGO

Método	Ventas	%	Total	Promedio
Tarjeta Crédito	3,827	58.9%	Q786,772.50	Q205.58
Tarjeta Débito	1,466	22.6%	Q309,301.80	Q210.98
Efectivo	1,207	18.6%	Q244,501.50	Q202.57

2.c DISTRIBUCIÓN DE VENTAS POR NAVEGADOR / CANAL

Canal	Ventas	%	Total	Promedio
Tienda Física	3,523	54.2%	Q719,298.50	Q204.17
Navegador 1	1,273	19.6%	Q276,221.80	Q216.98
Navegador 2	847	13.0%	Q175,415.60	Q207.10
Navegador 3	660	10.2%	Q132,472.20	Q200.72
Navegador 4	197	3.0%	Q37,167.70	Q188.67

2.c DISTRIBUCIÓN DE VENTAS POR BOLETÍN Y VALE

Boletín	Vale	Ventas	%	Promedio
No	No	3,136	48.2%	Q183.33
No	Sí	443	6.8%	Q170.66
Sí	No	2,110	32.5%	Q233.80
Sí	Sí	811	12.5%	Q242.57

3.a MESES CON MAYORES Y MENORES VENTAS (2021)

MAYORES ventas	Diciembre	577 ventas	Q124,038.70
MENORES ventas	Noviembre	493 ventas	Q99,385.50

3.b NAVEGADOR MÁS PREFERIDO Y MENOS POPULAR

Canal más usado en general : Tienda Física (3,523 ventas, 54.2%)
 Navegador más preferido : Navegador 1 (1,273 ventas, 19.6%)
 Navegador menos popular : Navegador 4 (197 ventas, 3.0%)

3.c VENTAS PAGADAS CONTRA ENTREGA O EN EFECTIVO

```
=====
RESPUESTA (criterio del auxiliar: MetodoPago = 0 cuenta como efectivo y como contra entrega)
Ventas contra entrega o en efectivo : 1,207 de 6,500 (18.6%)
Monto acumulado : Q244,501.50 de Q1,340,575.80 (18.2%)
```

```
DETALLE COMPLEMENTARIO – dónde se cobró ese efectivo
Originado en navegador (cobro en la entrega) : 633 ventas (52.4% del efectivo) Q129,138.10
Originado en tienda física (cobro en caja) : 574 ventas (47.6% del efectivo) Q115,363.40
```

```
=====
3.d USO DE BOLETINES Y VALES POR MES (2021)
=====
```

Mes	Ventas	Boletines	%	Vales	%
Enero	520	241	46.3%	100	19.2%
Febrero	545	259	47.5%	91	16.7%
Marzo	569	261	45.9%	133	23.4%
Abril	557	239	42.9%	88	15.8%
Mayo	530	251	47.4%	97	18.3%
Junio	543	228	42.0%	102	18.8%
Julio	565	236	41.8%	96	17.0%
Agosto	530	251	47.4%	102	19.2%
Septiembre	508	200	39.4%	120	23.6%
Octubre	563	260	46.2%	85	15.1%
Noviembre	493	233	47.3%	112	22.7%
Diciembre	577	262	45.4%	128	22.2%

```
Mes con más boletines : Diciembre (262)
Mes con más vales : Marzo (133)
```

```
=====
6. GENERACIÓN DE GRÁFICAS
=====
```

```
guardada: graficas\01-ventas-por-mes.png
guardada: graficas\02-metodo-pago.png
guardada: graficas\03-navegador.png
guardada: graficas\04-boletin-vale.png
guardada: graficas\05-boletin-vale-mensual.png
```

Segmentación de clientes y análisis de correlación

Previo a la segmentación se resalta un rasgo del conjunto de datos que condiciona todo lo que sigue: cada cliente registra exactamente una venta. Las 6,500 filas de la tabla venta corresponden a 6,500 valores distintos de `id_cliente`, de modo que cliente y transacción son la misma unidad de observación.

Esto tiene dos consecuencias prácticas. La primera es que no existe historial por cliente: no se puede medir recurrencia, frecuencia ni valor de vida, y cualquier segmentación es necesariamente una fotografía de una sola compra. La segunda es que el ticket promedio de un segmento y su gasto por cliente son el mismo número, lo que simplifica la lectura pero impide distinguir a un cliente que gasta mucho una vez de uno que gastaría poco muchas veces.


La columna `num_compra` sí existe y promedia 5.09, lo que sugiere que el sistema de origen sí lleva ese conteo; pero al haber una sola fila por cliente no es posible reconstruir esas compras anteriores ni sus montos.

Segmentación de clientes

1. Agrupación por edad

Se agruparon los 6,500 clientes en cinco tramos etarios. El rango observado va de los 18 a los 79 años, con una media de 36.3 años, por lo que no existe el tramo de menores de 18.

Rango	Clientes	% del total	Ticket promedio	Mediana	% con boletín	% con vale
18-25	1,249	19.2 %	Q207.82	Q136.50	40.6 %	17.1 %
26-35	1,946	29.9 %	Q212.66	Q145.30	48.2 %	20.3 %
36-45	1,946	29.9 %	Q204.70	Q136.45	48.9 %	20.4 %
46-55	1,013	15.6 %	Q199.63	Q132.90	37.6 %	17.4 %
56+	346	5.3 %	Q192.46	Q123.75	41.3 %	20.8 %



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Ticket promedio por rango de edad


El gasto: Existe una tendencia descendente ordenada a partir de los 26 años: el ticket baja de Q212.66 a Q192.46 conforme sube la edad. Pero la brecha entre el tramo que más gasta y el que menos es de Q20.21, un 10.5 % sobre la base más baja, y las cinco barras se apoyan sobre la línea del promedio general de Q206.24. Ningún tramo se despega. Es decir, la diferencia entre el segmento más rentable y el menos rentable equivale a menos de un tercio de lo que separa a un suscriptor del boletín de quien no lo es (Q54.47).

El tramo 56+ merece una advertencia metodológica. Es el ticket más bajo de la tabla, pero también el grupo más pequeño con 346 clientes: sobre esa base, una docena de compras atípicas mueve el promedio varios quetzales. La mediana confirma la dirección Q123.75 frente a Q145.30 del tramo 26-35, así que la tendencia es real, solo que su magnitud es pequeña y su segmento, marginal.

Dónde sí hay una diferencia aprovechable: El hallazgo útil de esta segmentación no está en el gasto sino en la última columna. La penetración del boletín no es pareja: alcanza el 48.9 % en el tramo 36-45 y apenas el 37.6 % en el de 46-55, once puntos porcentuales de diferencia. Como el boletín es la única variable del conjunto de datos que separa clientes por gasto de forma sustantiva, esa desigualdad de cobertura sí es accionable, y lo es precisamente en el tramo que hoy registra el segundo ticket más bajo.

Los tramos 26-35 y 36-45 concentran juntos el 59.8 % de los clientes y casi la misma proporción de la facturación. La empresa no tiene un problema de captación etaria, sino que tiene una base concentrada en adultos de 26 a 45 años que se comportan de forma prácticamente idéntica.

La objeción que el promedio no puede responder. Comparar medias invita a una réplica legítima: dos segmentos con el mismo promedio pueden esconder distribuciones muy distintas, y un ticket medio parecido podría convivir con clientes internamente muy diferentes. El diagrama de caja responde a eso mostrando la distribución completa de cada tramo, no solo su centro.



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Distribución del total de la venta por rango de edad

Las cinco cajas se solapan casi por completo. Los primeros cuartiles caben entre Q61.25 y Q74.78, los terceros entre Q255.90 y Q272.20, y las medianas entre Q123.75 y Q145.30: Q21.55 separan a la mediana más alta de la más baja, sobre una variable cuyo recorrido llega a Q3,169. No solo los promedios se parecen, sino que la mitad central de cada segmento ocupa prácticamente el mismo tramo de la escala. Vale notar que el orden de las medianas reproduce el de las medias, 26-35 arriba, 56+ abajo, lo que descarta que la tendencia descendente fuera un artefacto de los valores atípicos. La dirección es consistente; lo que el gráfico demuestra es que su magnitud es irrelevante frente a la dispersión interna de cada grupo. Dicho de otro modo, saber en qué tramo etario cae un cliente reduce muy poco la incertidumbre sobre lo que va a gastar.


2. Comportamiento de compra entre géneros

Indicador	Masculino	Femenino	Diferencia
Compras	3,372	3,128	244
Ticket promedio	Q204.46	Q208.16	Q3.70 (1.8 %)
Ticket mediano	Q137.30	Q137.60	Q0.30
Edad promedio	36.4 años	36.2 años	0.2 años
Compras con boletín	44.6 %	45.3 %	0.7 pp
Compras con vale	19.0 %	19.6 %	0.6 pp

Reparto del método de pago dentro de cada género, que es la comparación correcta al tratarse de grupos de distinto tamaño:

Género	Efectivo	Tarjeta de crédito	Tarjeta de débito
Masculino	17.8 %	59.9 %	22.2 %
Femenino	19.4 %	57.7 %	22.9 %

Reparto del método de pago dentro de cada género



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Reparto del método de pago por género

Las dos franjas son casi indistinguibles: la mayor brecha en cualquier método de pago es de 2.2 puntos porcentuales, y la mediana de gasto difiere en Q0.30. Cuando la media y la mediana coinciden en señalar una diferencia mínima, se puede descartar que el promedio esté siendo arrastrado por valores atípicos.

Hombres y mujeres compran por los mismos canales, pagan igual, tienen la misma edad promedio y responden al boletín y al vale en proporciones equivalentes. El género no describe dos comportamientos de compra distintos: describe el mismo comportamiento dos veces.

3. Agrupación por boletín y vale

Este es el cruce que sí separa clientes. Las cuatro combinaciones posibles:

Boletín	Vale	Compras	% del total	Ticket promedio	Facturación	% de la facturación
No	No	3,136	48.2 %	Q183.33	Q574,926.40	42.9 %
No	Sí	443	6.8 %	Q170.66	Q75,601.00	5.6 %
Sí	No	2,110	32.5 %	Q233.80	Q493,322.70	36.8 %
Sí	Sí	811	12.5 %	Q242.57	Q196,725.70	14.7 %



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Ticket promedio según boletín y vale

El mapa de calor hace evidente de un vistazo que la separación ocurre entre filas y no entre columnas: las dos celdas superiores (con boletín) son oscuras y las dos inferiores (sin boletín) son claras, mientras que moverse de izquierda a derecha: usar o no un vale, apenas cambia el tono. Quien manda es el boletín.

Agregando cada instrumento por separado:

Grupo	Compras	Ticket promedio
Con boletín	2,921	Q236.24
Sin boletín	3,579	Q181.76
Con vale	1,254	Q217.17
Sin vale	5,246	Q203.63

La diferencia por boletín es de Q54.47 por compra, un 30.0 % más. Los suscritos son el 44.9 % de las transacciones del año pero aportan el 51.5 % de la facturación (Q690,048.40 de Q1,340,575.80). Menos de la mitad de las ventas generando más de la mitad del dinero.

El vale exige leerse con cuidado. A primera vista parece sumar: quien usa vale gasta Q217.17 y quien no, Q203.63. Pero ese agregado es engañoso, porque los suscritos al boletín usan vale con mucha más frecuencia que los no suscritos (27.8 % frente a 12.4 %), de modo que la comparación directa está midiendo el efecto del boletín disfrazado de efecto del vale. Es un caso de libro de la paradoja de Simpson.

Al controlar por boletín el signo se invierte según el grupo:

Grupo	Con vale	Sin vale	Efecto del vale
Clientes sin boletín	Q170.66	Q183.33	-Q12.67 (-6.9 %)
Clientes con boletín	Q242.57	Q233.80	+Q8.77 (+3.8 %)


El mismo instrumento resta casi siete por ciento del ticket cuando se entrega a un cliente no suscrito y suma casi cuatro por ciento cuando se entrega dentro del boletín. Dicho de otro modo: el vale no funciona ni deja de funcionar, funciona según a quién se le dé. Repartido fuera del boletín, la empresa está pagando un descuento para obtener una compra más pequeña.

Análisis de correlación

Los tres contrastes se resolvieron sin dependencias externas: la correlación de Pearson y la de Spearman se calculan en PostgreSQL y los valores p de las tablas de contingencia (con 1 y 2 grados de libertad) tienen forma cerrada. Se usó el umbral convencional $\alpha = 0.05$.

1. Total de venta frente a edad de cliente

Estadístico	Valor
Tamaño de muestra	6,500
Correlación de Pearson (r)	-0.0252
Correlación de Spearman (ρ)	-0.0298
Varianza explicada (r^2)	0.064 %
Pendiente de la regresión	-Q0.48 por año de edad
Valor p	0.0419



Fuente: elaboración propia con base en los datos de ventas online 2021 cargados en PostgreSQL (N = 6,500 transacciones).

Dispersión entre edad y total a la venta

No existe una relación aprovechable entre la edad y el gasto. La nube de puntos no tiene estructura: para cualquier edad entre 18 y 79 años se observan ventas desde casi cero hasta más de Q1,000, y la recta de regresión es visualmente plana.

Este punto ilustra bien una distinción que conviene explicitar en un informe. El contraste formal sí rechaza la hipótesis de correlación nula: $p = 0.0419$, por debajo del 0.05 convencional. Sin embargo, r^2 indica que la edad explica el 0.064 % de la variación del gasto, es decir, seis centésimas de punto porcentual. La pendiente estimada es de menos de medio quetzal por año: entre un cliente de 20 y uno de 60 la regresión predice una diferencia de unos Q19, dentro de un rango de ventas que llega a los Q3,169.

Con 6,500 observaciones, cualquier desviación mínima respecto de cero alcanza significancia estadística. Significativo no es sinónimo de importante, y confundir ambas cosas es la vía más rápida a una campaña cara construida sobre ruido. Se calculó además la correlación de Spearman (-0.0298) para descartar que existiera una relación monótona no lineal que Pearson no capturara: tampoco la hay.

La edad no sirve para predecir cuánto va a gastar un cliente ni, por tanto, para priorizar inversión comercial.

2. Género frente a método de pago

Al ser dos variables categóricas, no aplica el coeficiente de Pearson. Se construyó la tabla de contingencia y se midió la asociación con chi-cuadrado y V de Cramér.

Género	Efectivo	Tarjeta de crédito	Tarjeta de bito	Total
Femenino	606	1,806	716	3,128
Masculino	601	2,021	750	3,372

Estadístico	Valor
Chi-cuadrado	3.7338 (2 grados de libertad)
V de Cramér	0.0240
Valor p	0.1546

No hay correlación entre el género y el método de pago preferido. Es el único de los tres contrastes que no alcanza significancia: con $p = 0.1546$ no se rechaza la hipótesis de independencia. En una escala donde 0 es independencia total y 1 es asociación perfecta, la V de Cramér marca 0.0240.

La lectura es doblemente sólida. Por un lado, la diferencia observada es tan pequeña que resulta compatible con el simple azar del muestreo. Por otro con 6,500 observaciones el contraste tiene potencia de sobra para detectar una asociación real si existiera; que ni siquiera con esa muestra aparezca señal indica que no la hay, y no que faltaran datos para verla.

Ambos géneros prefieren la tarjeta de crédito en proporciones casi idénticas (59.9 % frente a 57.7 %) y el efectivo pesa lo mismo en los dos (17.8 % y 19.4 %). Diseñar la pasarela de pago, las promociones de financiamiento o la comunicación de medios de pago en función del género no tiene respaldo en los datos

3. Boletines frente a vales

	Vale = Sí	Vale = No	Total
Boletín = Sí	811	2,110	2,921
Boletín = No	443	3,136	3,579

Estadístico	Valor
Chi-cuadrado	244.5525 (1 grado de libertad)
V de Cramér	0.1940
Valor p	4×10^{-55}

Sí existe correlación entre el uso de boletines y el de vales, y es la única asociación significativa de este bloque. El valor p es efectivamente cero: la independencia queda descartada sin margen de duda.

Traducido a tasas de uso:

- Entre los suscritos al boletín, el **27.8 %** usó vale.
- Entre los no suscritos, solo el **12.4 %**.
- Los suscritos usan vale **2.24 veces más**.

La V de Cramér de 0.1940 indica una asociación débil en magnitud pero inequívoca en existencia: saber que un cliente está suscrito al boletín más que duplica la probabilidad de que

su compra lleve vale, pero sigue habiendo 2,110 suscritos que no usaron ninguno y 443 no suscritos que sí. No es una relación determinista.

La explicación más económica es operativa antes que conductual: el boletín es el canal por el que se distribuye el vale. Quien no está suscrito simplemente tiene menos ocasiones de recibir uno. Bajo esa lectura, el coeficiente no mide una afinidad del cliente por los descuentos, sino la huella del propio mecanismo de reparto de la empresa.

Y aquí es donde este punto se conecta con el 4.c y deja de ser un dato estadístico para volverse una decisión de negocio: los 443 vales que llegaron a clientes no suscritos son exactamente los que destruyen valor (−Q12.67 de ticket), mientras que los 811 que se entregaron dentro del boletín son los que suman (+Q8.77). La correlación existe, es imperfecta, y su parte imperfecta es la que está costando dinero.

Síntesis del bloque

De las tres relaciones investigadas, dos resultan inservibles para segmentar y una concentra todo el valor:

Relación	Coeficiente	¿Significativa ?	¿Útil para decidir?
Edad - total de la venta	$r = -0.0252$	Sí ($p = 0.042$)	No , explica el 0.064 % del gasto
Género - método de pago	$V = 0.0240$	No ($p = 0.155$)	No , no se rechaza la independencia
Boletín - vale	$V = 0.1940$	Sí ($p \approx 0$)	Sí , revela un reparto mal dirigido

La conclusión transversal es que las variables demográficas no segmentan a esta clientela y la variable conductual sí. Edad y género están disponibles, son fáciles de usar y son las que intuitivamente se usarían para armar campañas; los datos muestran que no discriminan nada.

En cambio, la suscripción al boletín, que la empresa controla, que no requiere comprar información externa y que ya está registrada, separa dos grupos con Q54.47 de diferencia por transacción.

El corolario incómodo es que la empresa hoy no tiene un segmento demográfico desatendido que capturar: tiene un instrumento propio, el boletín, que llega a menos de la mitad de sus compras y cuya cobertura además es desigual por edad.

Limitaciones

1. **Ninguno de los coeficientes prueba causalidad.** Que los suscritos al boletín gasten un 30 % más no demuestra que el boletín los haga gastar más; es igual de compatible con que el cliente ya interesado sea quien decide suscribirse. Separar ambas explicaciones requiere un experimento controlado, no más consultas sobre estos mismos datos.
2. **Una sola compra por cliente.** Al no existir historial, toda la segmentación es una fotografía instantánea. No se puede afirmar que un segmento sea «más leal» ni calcular valor de vida del cliente.
3. **Un solo año de datos.** Los patrones corresponden a 2021 y no hay 2020 ni 2022 para verificar si se sostienen.
4. **Los tramos etarios son una convención.** Se usaron cortes estándar de mercadeo (18-25, 26-35, ...). Otros cortes moverían los promedios de cada celda, aunque no la conclusión de fondo: la correlación continua entre edad y gasto es prácticamente nula, y eso no depende de cómo se agrupe.
5. **El tramo 56+ tiene base reducida** (346 clientes, 5.3 %). Sus promedios son los menos estables de la tabla y no deberían sostener por sí solos ninguna decisión.
6. **No se conoce la política de reparto de vales.** La interpretación de que el boletín es el canal de distribución del vale es la más razonable dado el patrón observado, pero el conjunto de datos no registra cómo se emitió cada vale.

Resultados detallados

Salida completa del bloque de segmentación y correlación, incluidos los contrastes de significancia de los tres coeficientes.

Salida de análisis/segmentacion.py

Segmentación de clientes y análisis de correlación · ventas 2021

4.a SEGMENTACIÓN DE CLIENTES POR RANGO DE EDAD

Rango	Clientes	%	Ticket prom.	Mediana	Boletín	Vale
18-25	1,249	19.2%	Q207.82	Q136.50	40.6%	17.1%
26-35	1,946	29.9%	Q212.66	Q145.30	48.2%	20.3%
36-45	1,946	29.9%	Q204.70	Q136.45	48.9%	20.4%
46-55	1,013	15.6%	Q199.63	Q132.90	37.6%	17.4%
56+	346	5.3%	Q192.46	Q123.75	41.3%	20.8%

Ticket más alto : 26-35 Q212.66

Ticket más bajo : 56+ Q192.46

Brecha entre extremos: Q20.21 (10.5% sobre el rango más bajo)

Facturación total segmentada: Q1,340,575.80 · 6,500 clientes

4.b COMPORTAMIENTO DE COMPRA POR GÉNERO

Género	Compras	Ticket prom.	Mediana	Edad prom.	Boletín	Vale
Masculino	3,372	Q204.46	Q137.30	36.4	44.6%	19.0%
Femenino	3,128	Q208.16	Q137.60	36.2	45.3%	19.6%

Reparto del método de pago dentro de cada género (%)

Género	Efectivo	Tarjeta Crédito	Tarjeta Débito
Femenino	19.4%	57.7%	22.9%
Masculino	17.8%	59.9%	22.2%

Diferencia de ticket entre géneros : Q3.70 (1.8%)

Mayor brecha en método de pago : 2.2 puntos porcentuales

4.c SEGMENTACIÓN POR BOLETÍN Y VALE

Boletín	Vale	Compras	%	Ticket prom.	Facturación	% fact.
No	No	3,136	48.2%	Q183.33	Q574,926.40	42.9%
No	Sí	443	6.8%	Q170.66	Q75,601.00	5.6%
Sí	No	2,110	32.5%	Q233.80	Q493,322.70	36.8%

Sí	Sí	811	12.5%	Q242.57	Q196,725.70	14.7%
----	----	-----	-------	---------	-------------	-------

Efecto de cada instrumento por separado

Grupo	Compras	Ticket prom.
-------	---------	--------------

Con boletín	2,921	Q236.24
Sin boletín	3,579	Q181.76
Con vale	1,254	Q217.17
Sin vale	5,246	Q203.63

Diferencia por boletín : Q54.47 (+30.0%)

Efecto del vale controlando por boletín (evita la paradoja de Simpson)

Boletín = No → con vale Q170.66 vs sin vale Q183.33 Q-12.67 (-6.9%)

Boletín = Sí → con vale Q242.57 vs sin vale Q233.80 Q8.77 (+3.8%)

5.a CORRELACIÓN ENTRE TOTAL DE LA VENTA Y EDAD DEL CLIENTE

Tamaño de muestra : 6,500 observaciones

Correlación de Pearson (r) : -0.0252

Correlación de Spearman : -0.0298

Varianza explicada (r²) : 0.064% del gasto

Contraste H0: r = 0 : p = 0.04189 → significativa (p < 0.05)

Interpretación : La relación lineal es prácticamente nula y negativa; correlación no implica causalidad.

Lectura: el contraste rechaza por poco la hipótesis de correlación cero, pero r² muestra que la edad explica una fracción despreciable del gasto. Con 6,500 observaciones incluso una desviación mínima respecto de cero resulta significativa: el hallazgo es estadísticamente detectable y a la vez irrelevante para la operación.

5.b ASOCIACIÓN ENTRE GÉNERO Y MÉTODO DE PAGO

Tabla de contingencia (cantidad de ventas)

Género	Efectivo	Tarjeta Crédito	Tarjeta Débito
Femenino	606	1,806	716
Masculino	601	2,021	750

Chi-cuadrado : 3.7338 (2 grados de libertad)

V de Cramér : 0.0240

Contraste de independencia : p = 0.1546 → NO significativa (p ≥ 0.05)

Interpretación : La asociación entre las variables es muy débil; asociación no implica causalidad.

Lectura: no se rechaza la independencia. Género y método de pago se comportan como variables no relacionadas en este conjunto de datos.

5.c ASOCIACIÓN ENTRE EL USO DE BOLETINES Y VALES

=====

Tabla de contingencia (cantidad de ventas)

	Vale = Sí	Vale = No	Total
Boletín = Sí	811	2,110	2,921
Boletín = No	443	3,136	3,579

Chi-cuadrado : 244.5525 (1 grado de libertad)

V de Cramér : 0.1940

Contraste de independencia : $p = 4e-55 \rightarrow$ significativa ($p < 0.05$)

Interpretación : La asociación entre las variables es débil; asociación no implica causalidad.

Tasa de uso de vale entre suscritos al boletín : 27.8%

Tasa de uso de vale entre NO suscritos al boletín : 12.4%

Razón de tasas: los suscritos usan vale 2.24 veces más.

Lectura: es la única asociación de este bloque que resulta significativa.

El vale no se distribuye de forma pareja: se concentra en quienes ya reciben el boletín, que es el canal por el que se entrega.

=====

Correlación de Pearson (r) : -0.0252

Correlación de Spearman : -0.0298

Varianza explicada (r^2) : 0.064% del gasto

Contraste $H_0: r = 0$: $p = 0.04189 \rightarrow$ significativa ($p < 0.05$)

Interpretación : La relación lineal es prácticamente nula y negativa; correlación no implica causalidad.

Lectura: el contraste rechaza por poco la hipótesis de correlación cero,

pero r^2 muestra que la edad explica una fracción despreciable del gasto.

Con 6,500 observaciones incluso una desviación mínima respecto de cero resulta significativa: el hallazgo es estadísticamente detectable y a la vez irrelevante para la operación.

=====

5.d ASOCIACIÓN ENTRE GÉNERO Y MÉTODO DE PAGO

=====

Tabla de contingencia (cantidad de ventas)

Género	Efectivo	Tarjeta Crédito	Tarjeta Débito
Femenino	606	1,806	716
Masculino	601	2,021	750

Chi-cuadrado : 3.7338 (2 grados de libertad)

V de Cramér : 0.0240

Contraste de independencia : $p = 0.1546 \rightarrow$ NO significativa ($p \geq 0.05$)

Interpretación : La asociación entre las variables es muy débil; asociación no implica causalidad.

Lectura: no se rechaza la independencia. Género y método de pago se comportan como variables no relacionadas en este conjunto de datos.

=====

5.e ASOCIACIÓN ENTRE EL USO DE BOLETINES Y VALES

=====

Tabla de contingencia (cantidad de ventas)

	Vale = Sí	Vale = No	Total
Boletín = Sí	811	2,110	2,921
Boletín = No	443	3,136	3,579

Chi-cuadrado : 244.5525 (1 grado de libertad)

V de Cramér : 0.1940

Contraste de independencia : $p = 4e-55 \rightarrow$ significativa ($p < 0.05$)

Interpretación : La asociación entre las variables es débil; asociación no implica causalidad.

Tasa de uso de vale entre suscritos al boletín : 27.8%

Tasa de uso de vale entre NO suscritos al boletín : 12.4%

Razón de tasas: los suscritos usan vale 2.24 veces más.

Lectura: es la única asociación de este bloque que resulta significativa.

El vale no se distribuye de forma pareja: se concentra en quienes ya reciben el boletín, que es el canal por el que se entrega.

=====

6. GENERACIÓN DE GRÁFICAS

=====

guardada:graficas\06-segmentacion-edad.png

guardada:graficas\07-genero-metodo-pago.png

guardada:graficas\08-dispersion-edad-venta.png

guardada:graficas\09-boletin-vale-ticket.png

Conclusiones

1. **Conclusión Clave 1:**
2. **Conclusión Clave 2:**
3. **Conclusión Clave 3: El newsletter es lo único que realmente mueve la aguja, y lo estamos desaprovechando**

Después de revisar las 6,500 ventas del año buscamos lo obvio primero, saber si conociendo la edad o el género de un cliente uno puede adivinar cuánto va a gastar. La respuesta corta es que no, y no por poco.

Con la edad medimos qué tanto se mueven juntas las dos cosas, es decir, si los clientes mayores gastan más o si son los jóvenes los que dejan más dinero. El resultado fue de -0.025 en una escala que va de -1 a 1, donde 1 significaría que a más edad siempre más gasto, -1 lo contrario y 0 significa que no hay ninguna relación. Estamos parados prácticamente encima del cero. Dicho de otro modo: si alguien te dice que un cliente tiene 25 años y otro tiene 60, esa información no te ayuda absolutamente en nada a predecir cuál de los dos va a gastar más. Y no es que la muestra sea pequeña o el rango de edades sea angosto, porque tenemos gente desde los 18 hasta los 79 años, con un promedio de 36. Simplemente la edad no explica el gasto en este negocio.

Con el género pasa lo mismo. Medimos si hombres y mujeres eligen métodos de pago distintos y el indicador dio 0.024, otra vez sobre una escala de 0 a 1 donde 0 quiere decir que las dos cosas son independientes. Traducido: hombres y mujeres pagan igual, con las mismas proporciones de tarjeta de crédito, débito y efectivo. Y cuando comparamos cuánto gasta cada quien por compra, los hombres dejan Q204.46 en promedio y las mujeres Q208.16. Son Q3.70 de diferencia, menos de dos por ciento, una brecha tan chica que se explica sola por el azar de qué persona entró a comprar qué día. Para tener contexto, el ticket promedio de todo el negocio es de Q206.24 y la mitad de las ventas están por debajo de Q137.35, así que esos Q3.70 no representan nada.

La lectura práctica es directa, armar campañas separadas para hombres y mujeres, o segmentar por rangos de edad, es gastar tiempo y presupuesto en una división que los datos no respaldan. No hay un cliente joven que gaste distinto ni un segmento femenino que pague diferente. Todos se comportan parecido.

Ahora, donde sí aparece una diferencia de verdad es en el boletín informativo, y es una diferencia que salta a la vista. De las 6,500 ventas del año, 2,921 vinieron de clientes suscritos y esas compras promediaron Q236.24 cada una. Las otras 3,579 ventas son de clientes no suscritos y promediaron Q181.76. La diferencia son Q54.48 más por transacción, un 30% arriba. Para dimensionarlo mejor: los suscritos son apenas el 45% de las transacciones del año pero aportan el 51.5% de toda la facturación. Menos de la mitad de las ventas generando más de la mitad del dinero. Ninguna otra variable del conjunto de datos separa a los clientes con esa claridad.

Hay que ser honestos con lo que estos números sí prueban y lo que no. Lo que vemos es que los suscritos gastan más, no que el boletín los haga gastar más. Puede que suscribirse sea lo que despierta el interés, pero también puede ser al revés: que el cliente que ya venía convencido y con ganas de comprar sea justamente el que se toma la molestia de dejar su correo. En ese caso el boletín no estaría causando nada, solo estaría marcando quiénes ya eran buenos clientes de antemano. Para saber cuál de las dos cosas es, habría que hacer una prueba controlada: tomar dos grupos parecidos de clientes, mandarles el boletín a uno y al otro no, y ver si el gasto se separa. Sin ese experimento no podemos afirmar causa y efecto.

Pero para efectos de decidir qué hacer mañana, la distinción casi no importa. Sea porque el boletín los convierte o porque el boletín los identifica, la suscripción es hoy la mejor señal que tenemos para saber quién es un cliente valioso. Y eso ya es suficiente para actuar: conviene empujar la suscripción en cada punto de contacto, dejar de repartir vales sueltos a quien no está suscrito porque ahí solo se regala margen, y usar el vale como incentivo dentro del boletín, que es el único lugar donde demostró sumar en lugar de restar.

4. Conclusión Clave 4: La empresa se cree digital, pero dos de cada tres ventas necesitan que alguien esté ahí en persona

El enunciado describe a la empresa como un negocio que nació vendiendo en línea y que apenas está dando el salto a una sucursal física. Los datos de 2021 dicen otra cosa. De las 6,500 transacciones del año, 3,523 quedaron registradas en tienda física: el 54.2%. El canal que todavía se trata como el proyecto nuevo ya carga con más de la mitad de la operación, y lleva haciéndolo un año completo.

El segundo dato viene del dinero. Durante 2021 hubo 1,207 ventas pagadas contra entrega o en efectivo, el 18.6% del total, mientras que la tarjeta de crédito se llevó el 58.9% y la de débito el 22.6%. Casi una de cada cinco transacciones del año se cerró con billetes de por medio.

Al cruzar ese pago con el canal de origen la cifra se vuelve más interesante. De esas 1,207 ventas en efectivo, 574 salieron de la tienda física y las otras 633 entraron por un navegador. Un cobro en efectivo que nace en internet no se liquida en el mostrador, se liquida en la puerta del cliente, así que ese medio millar largo de transacciones representa reparto con cobro en mano. El dato estaba ahí desde el principio, solo que repartido entre dos columnas que nadie había cruzado. Sumadas las dos cosas —las 3,523 ventas de mostrador más las 633 contra entrega— salen 4,156 transacciones que exigen que una persona entregue producto o reciba dinero físicamente. Es el 63.9% del año. La infraestructura que sostiene a este negocio no es el carrito de compras: es el mostrador, la ruta de reparto y el manejo de efectivo. Cualquier plan que se arme asumiendo que el crecimiento pasa por optimizar la web va a estar apuntando al tercio equivocado del negocio.

La otra mitad del hallazgo está en el calendario. Las ventas mensuales son sorprendentemente parejas: el año se mueve entre 493 y 577 transacciones por mes, es decir, entre un 9% por debajo y un 6.5% por encima del promedio de 542. No hay temporadas fuertes ni temporadas muertas, hay un negocio de goteo constante. Con una excepción incómoda: noviembre es el peor mes del año con 493 ventas, justo antes de que diciembre

cierre como el mejor con 577. Diciembre vende 84 transacciones más que noviembre, un 17% arriba, y esos dos meses consecutivos concentran el máximo y el mínimo de los doce. Para un comercio que ya opera tienda física, noviembre debería ser el mes de arranque de la temporada alta, no el hoyo del año.

El calendario comercial tampoco acompaña. Los boletines se disparan en diciembre (262 ventas asociadas, el máximo anual) pero los vales alcanzan su pico en marzo, con 133. La correlación entre ambas series mensuales es de -0.077, es decir, prácticamente nula: los dos instrumentos se mueven cada uno por su lado. Septiembre lo resume bien, porque registra la tasa más baja de boletines del año (39.4%) y al mismo tiempo la más alta de vales (23.6%); octubre hace lo contrario, con buena cobertura de boletín (46.2%) y el mínimo anual de vales, apenas 85 ventas y un 15.1%. Nadie parece estar coordinando ambas palancas, y noviembre — el mes flojo — tiene una de las tasas de boletín más altas del año (47.3%) sin que eso se traduzca en ventas. El esfuerzo comercial está llegando, pero llegando descoordinado.

Hay que ser honestos con el alcance de todo esto. El conjunto de datos registra qué se pagó y por dónde entró la venta, pero no registra el porqué: no hay campañas, ni costos por canal, ni motivo de la caída de noviembre. La separación entre efectivo de mostrador y cobro en la puerta descansa en un supuesto razonable pero supuesto al fin, que es que el efectivo no se cobra a distancia; el total de 1,207 ventas, en cambio, sale directo del campo MetodoPago y no admite discusión. El patrón mensual corresponde además a un solo año, así que llamarlo estacionalidad sería exagerado mientras no tengamos 2020 o 2022 para comparar. Lo que sí queda firme, porque no depende de ninguna interpretación, es el reparto: más de la mitad de las ventas ocurrieron presencialmente, casi una de cada cinco se pagó en efectivo, y el año fue plano con un bache justo en noviembre.

Recomendaciones

Acciones concretas propuestas

1. Dos acciones concretas Clave #1

- **Acción 1**
- **Acción 2**

2. Dos acciones concretas Clave #2

- **Acción 1**
- **Acción 2**

3. Dos acciones concretas Clave #3

- **Acción 1** Dejar de regalar cupones a cualquiera y usarlos para sumarsuscriptores al boletín
Los números no mienten: darle un vale de descuento a alguien que no está suscrito al boletín solo nos hace perder dinero. De hecho, el ticket promedio cae un 7.8%; es decir, estamos pagando para cobrar menos. La propuesta es simple: cortar la entrega masiva de vales y dar cupones únicamente a quienes se registren en el boletín. El objetivo es pasar de un 44.9% a un 60% de compras ligadas al boletín en un año. Tomando como base las 6,500 ventas al año, si logramos pasar unas 979 compras al grupo de suscriptores (donde el ticket es Q497.09 más alto), estaríamos sumando unos Q486,651 de ingreso extra al año. Para medirlo, solo hay que revisar mes a mes qué porcentaje de las ventas vienen de clientes con boletín. Además, esto no requiere presupuesto nuevo, simplemente mover dinero que ya nos estamos gastando.
- **Acción 2** Hacer un test A/B para ver si el boletín hace que gasten más o si solo atrae a los mejores clientes Sabemos que los suscriptores gastan más, pero no si gastan más por culpa del boletín o si simplemente la gente que más nos compra es la que decide suscribirse. Antes de meterle más dinero a esto, vale la pena salir de dudas. Propongo tomar a dos grupos al azar de clientes no suscritos y ofrecerle el boletín solo a uno de ellos para comparar sus compras durante un trimestre: Si el grupo que recibió la invitación sube su ticket promedio a Q2,139.31: Confirmamos que el boletín genera la venta y aceleramos la Acción 1 con toda la confianza. Si ambos grupos se quedan estancados cerca de los Q1,642.22: Significa que el

boletín solo sirve para ubicar a los clientes fieles que ya teníamos, por lo que valdría más la pena enfocar el presupuesto en fidelización y retención. Hacer esta prueba no cuesta casi nada porque usa la herramienta de correo que ya tenemos, y nos evita el riesgo de meterle un gran presupuesto a una simple coincidencia en los datos.

4. Dos acciones concretas Clave #4

- **Acción 1** Adelantar la campaña de fin de año a la primera semana de noviembre. Noviembre cierra como el peor mes del año con 493 ventas y diciembre como el mejor con 577. Están pegados, y esa diferencia de 84 transacciones es la brecha más grande entre dos meses consecutivos de todo 2021. Lo raro es que noviembre ya recibe esfuerzo comercial: el 47.3% de sus ventas vienen de clientes con boletín, una de las tasas más altas del año. El mensaje está saliendo, pero saliendo tarde o diciendo lo equivocado. La propuesta es correr el arranque de la campaña de fin de año del inicio de diciembre a la primera semana de noviembre, sin presupuesto adicional: es el mismo envío, movido cuatro semanas. La meta es llevar noviembre de 493 a 542 ventas, que es simplemente el promedio mensual del año, sin pedirle que sea un mes estrella. Son 49 transacciones de diferencia y se mide en el corte mensual que ya generamos. Si noviembre sube y diciembre se mantiene, ganamos volumen real. Si noviembre sube y diciembre baja en la misma proporción, no ganamos plata pero aprendemos algo igual de útil, que la demanda de fin de año es fija y solo se está moviendo de mes; en ese caso conviene dejar de gastar en empujarla y aprovechar para descargar la operación de diciembre, que es cuando la tienda física está más saturada.
- **Acción 2** Poner el contra entrega bajo control antes de que crezca. Las 633 ventas en línea pagadas en efectivo al momento de la entrega son el 21.3% de todo lo que se vende por internet, y hoy nadie las está gestionando como lo que son: un producto financiero con costo. Cada una implica que un repartidor cargue cambio, que el dinero se concilie a mano y que exista el riesgo de que el cliente no abra la puerta o se arrepienta. Ese costo no aparece en ningún reporte porque el dataset ni siquiera registra si el pedido se entregó. Propongo dos movimientos que se ejecutan juntos. El primero es empezar a registrar el

estado final de cada pedido contra entrega —entregado, rechazado, reagendado— porque ahora mismo estamos ciegos: puede que el 5% se caiga o puede que el 25%, y la diferencia entre esos dos números decide si esta modalidad es rentable. El segundo es ofrecer un descuento pequeño, del orden del 3%, a quien pague por adelantado con tarjeta, y medir cuántos migran. La meta es bajar el contra entrega del 21.3% al 15% de las ventas en línea durante el primer año, unas 190 transacciones que dejarían de requerir manejo de efectivo. El descuento se paga solo si el costo real de una entrega fallida resulta mayor al 3% del ticket, y eso lo vamos a saber recién cuando exista el registro del primer movimiento. Por eso el orden importa: primero medir, después incentivar.

5. Dos acciones concretas Segmentación y correlación

- **Acción 1** Retirar la edad y el género como criterios de segmentación y reconstruir los segmentos sobre boletín y vale. Los tres contrastes del punto 5 son concluyentes en la misma dirección. La edad explica el 0.064% de la variación del gasto, y el género y el método de pago son estadísticamente independientes ($p = 0.155$). En cambio, el cruce de boletín y vale separa cuatro grupos con tickets de Q170.66, Q183.33, Q233.80 y Q242.57. La empresa está segmentando por las dos variables que no discriminan nada e ignorando la que sí. La propuesta concreta es sustituir la matriz de segmentos actual por las cuatro celdas de boletín $\times$ vale, y establecer como regla que ninguna campaña se defina por tramo etario o por género salvo que exista una razón de producto que lo justifique, no una razón de gasto, porque esa ya se descartó. La implementación es una reconfiguración de audiencias en la herramienta de correo que ya está en uso; no implica comprar datos ni contratar nada. El indicador de cumplimiento es simple y auditable: al cierre del trimestre, el 100% de las campañas enviadas debe tener como criterio de audiencia la suscripción al boletín o el uso de vale, y cero campañas deben estar definidas por edad o género. El beneficio no es un ingreso incremental directo sino la eliminación del costo de producir y enviar variantes creativas por segmento demográfico que, según los datos, le hablan al mismo cliente dos veces.

-
- **Acción 2** Cerrar la brecha de cobertura del boletín en los tramos 46-55 y 18-25. La penetración del boletín no es pareja por edad: alcanza el 48.9% en el tramo 36-45 pero cae al 37.6% en el de 46-55 y al 40.6% en el de 18-25. Once puntos porcentuales de diferencia en el único instrumento que demostró mover el ticket, y precisamente en el tramo 46-55, que registra el segundo ticket más bajo de la tabla (Q199.63). La propuesta es una campaña de captación dirigida a esos dos tramos con la meta de llevarlos al 48.9% que ya alcanza el tramo mejor cubierto. Sobre la base de 2021 son unos 218 clientes adicionales suscritos, que al pasar del ticket sin boletín (Q181.76) al ticket con boletín (Q236.24) representarían alrededor de Q11,900 anuales. Contando también los ajustes menores de los tramos 26-35 y 56+, la cobertura global pasaría del 44.9% al 48.9% y el incremental rondaría los Q14,000, un 1.05% de la facturación anual. Conviene ser honesta con la magnitud: es una mejora modesta, no un cambio de trayectoria. Su valor está en la relación entre esfuerzo y riesgo, porque usa un canal que ya existe, se dirige a clientes que ya compraron y su resultado se mide con el corte de cobertura por tramo etario que este mismo análisis deja construido. Y tiene un segundo beneficio que no aparece en el cálculo: si al subir la cobertura en 46-55 el ticket de ese tramo no se mueve, se obtiene evidencia observacional de que el boletín identifica buenos clientes en lugar de crearlos.

Respuestas a preguntas de alcance

- **Pregunta 8.a: ¿Cómo podrían los insights ayudar a diferenciarse de la competencia?**
- **Pregunta 8.b: ¿Qué decisiones estratégicas podrían tomarse para aumentar las ventas?**
- **Pregunta 8.c: ¿Cómo podría este análisis de datos ayudar a la empresa a ahorrar costos o mejorar la eficiencia operativa?**

El análisis nos permite ahorrar dinero por dos lados distintos, y vale la pena verlos por separado porque impactan diferentes presupuestos:

- ✓ **Cortar de raíz los gastos de marketing que no sirven.** A veces el mayor ahorro viene de dejar de hacer lo que no funciona. Con una correlación de -0.019 entre edad y compra, y un 0.024 entre género y forma de pago, queda claro que meterle presupuesto a segmentar campañas por edad o género es tirar el dinero a la basura. Igualmente, regalar vales a clientes no suscritos nos hace perder un 7.8% en el ticket promedio; o sea, le estamos pagando al cliente para que nos compre menos. Frenar esto es un ahorro inmediato y no nos cuesta ni un centavo.
- ✓ **Ajustar la parte técnica y operativa a la realidad.** No tiene sentido tratar a todos los canales por igual. El Navegador 4 solo representa 197 ventas (el 3% del total), mientras que el Navegador 1 se lleva el 42.8% de todo el volumen digital. Gastar el mismo tiempo y dinero en mantenimiento o pruebas de compatibilidad para un navegador que casi nadie usa es un desperdicio. Si concentramos el trabajo del equipo de sistemas en el canal principal y reducimos la atención al marginal, liberamos recursos sin que el usuario note la diferencia.

6. **Pregunta 8.d: ¿Qué datos adicionales recomendarían para obtener insights aún más valiosos en el futuro?**

Trabajar con estas doce columnas dejó claro dónde están los techos del análisis. Cada límite que encontramos apunta a un dato que no se está capturando, y esta es la lista ordenada por lo que más cambiaría las decisiones si existiera.

- ✓ **Qué se vendió.** Es la ausencia más grande y la más incómoda. El dataset dice cuánto se pagó, cuándo y por dónde, pero no dice qué compró la gente. Sin producto ni categoría

no se puede calcular rotación, ni armar recomendaciones, ni saber si diciembre vende más por volumen o porque se venden cosas más caras. Un identificador de producto y su categoría convertirían este análisis en uno de surtido, que es donde de verdad se toman las decisiones de compra e inventario.

- ✓ **Costo y margen por transacción.** Todo el análisis está construido sobre ingresos, y eso obliga a asumir que vender más siempre es mejor. No lo es. Sin costo no hay forma de saber si el descuento del vale se paga solo, si la tienda física es más rentable que el reparto o si el canal que más factura es también el que menos deja. Es el dato que separa un reporte de ventas de uno de rentabilidad.
- ✓ **Estado final del pedido.** Detectamos 633 ventas en línea pagadas en efectivo, que se cobran cuando el producto llega a la puerta. No sabemos cuántas de esas efectivamente llegaron. Un campo de estado entregado, rechazado, reagendado, devuelto, revelaría si esa modalidad es un canal sano o una fuga silenciosa. Hoy estamos midiendo ventas que quizá nunca se concretaron.
- ✓ **Marca de tiempo completa y documentación de la columna Tiempo.** Solo tenemos la fecha, sin hora. Saber a qué hora compra la gente permitiría dimensionar turnos en la tienda y programar los envíos del boletín cuando alguien los va a abrir. A esto se suma un problema de metadatos: la columna trae valores alrededor de 767 sin ninguna unidad declarada. Pueden ser segundos de sesión, minutos hasta la entrega o cualquier otra cosa, y como no está documentada tuvimos que dejarla fuera del análisis. Un diccionario de datos habría recuperado una variable completa.
- ✓ **Origen del tráfico y campañas activas.** Noviembre es el mes más flojo del año, con 493 ventas, y no tenemos manera de saber por qué. Registrar de dónde llegó cada visita y qué campaña estaba corriendo en cada fecha convertiría hallazgos descriptivos en explicaciones. Ahora mismo podemos decir qué pasó, pero no por qué, y esa distinción es la que separa un análisis que informa de uno que sirve para actuar.
- ✓ **Dispositivo y sucursal.** Los canales están etiquetados como Navegador 1 a Navegador 4 sin decir cuáles son ni si la diferencia es de navegador, de dispositivo o de aplicación. Saber si el Navegador 4 tiene 197 ventas porque casi nadie lo usa o porque algo se rompe

en su proceso de pago son dos diagnósticos opuestos con soluciones opuestas. Del lado físico pasa igual: si la empresa abre más sucursales, sin un identificador de tienda todas las ventas presenciales seguirán apareciendo como un solo bloque indistinguible.

- ✓ ***Fecha de suscripción al boletín.*** Los suscriptores gastan más, pero con los datos actuales no se puede saber si empezaron a gastar más después de suscribirse o si ya gastaban más desde antes. Guardar la fecha en que cada cliente se suscribió permitiría comparar su comportamiento previo y posterior, y resolver con datos ya existentes una pregunta que hoy exige montar un experimento.

Vale la pena señalar que los primeros tres puntos no requieren tecnología nueva: son campos que el sistema transaccional casi con seguridad ya maneja y que simplemente no se están arrastrando hasta el conjunto de datos analítico. El costo de agregarlos es bajo comparado con lo que se gana.

7. Pregunta 8.e: ¿Implementar un chat conversacional de IA afectaría a la empresa para que entregue el análisis de los datos a futuro?

Sí, y de forma sustancial, pero el efecto no es el que suele venderse. No se trata de que la inteligencia artificial descubra hallazgos que el equipo no vio, sino de que elimina la espera entre una pregunta de negocio y su respuesta numérica. Vale la pena separar lo que este proyecto demuestra que el agente sí hace de lo que no puede hacer, porque de esa distinción depende que la inversión valga la pena.

- ✓ ***Lo que cambia de verdad: la velocidad y quién puede preguntar.*** Hoy, cuando alguien de comercial quiere saber cuánto vendió noviembre o qué tramo etario deja más margen, la pregunta entra a una cola: alguien la traduce a SQL, la ejecuta, la formatea y la devuelve. Ese ciclo se mide en horas o días, y su costo real no es el tiempo del analista sino las preguntas que nunca se hacen porque no valen el trámite. Con el agente implementado, las dieciséis preguntas del alcance de esta práctica se responden en lenguaje natural y en segundos, sin que quien pregunta sepa SQL. El analista deja de ser el intermediario de consultas rutinarias y queda libre para el trabajo que sí requiere criterio.

-
- ✓ ***Por qué esta implementación es confiable y un chatbot genérico no lo sería.*** Aquí está la decisión de arquitectura que más importa. El agente no recibe la base de datos ni el archivo CSV para que los interprete: recibe doce herramientas del MCPServer, cada una respaldada por una consulta SQL fija y revisada. Cuando alguien pregunta por la correlación entre edad y venta, el modelo no calcula nada; invoca `obtener_correlacion_venta_edad` y el `corr()` de PostgreSQL devuelve -0.0252 . El papel del modelo se limita a entender la pregunta, elegir la herramienta y redactar la respuesta. La diferencia es enorme en términos de riesgo. Un modelo al que se le pega un CSV en el chat puede equivocarse al sumar y presentar el error con total seguridad. Aquí eso no puede ocurrir, porque los números no los produce el modelo. Además la conexión es de solo lectura y las credenciales viven en variables de entorno, de modo que el agente no puede alterar ni exponer la base. Es la diferencia entre una herramienta de consulta y un generador de texto plausible.
 - ✓ ***Los tres límites que la empresa debe asumir antes de decidir.***
 - *Primero, el agente solo sabe lo que sus herramientas exponen.* Responde las doce consultas registradas y nada más. El hallazgo más valioso de nuestro bloque, que el vale resta 6.9% de ticket a los no suscritos y suma 3.8% a los suscritos, una vez controlado el efecto del boletín, no salió de ninguna de las doce herramientas: exigió sospechar de un promedio agregado, reconocer una paradoja de Simpson y escribir una consulta nueva. El agente entrega respuestas; no formula las preguntas correctas.
 - *Segundo, entregar el dato no es entregar el análisis.* El agente puede devolver $r = -0.0252$ con toda exactitud y aun así quien lo lea puede concluir que hay relación negativa, enfoquémonos en clientes jóvenes. El número correcto y la decisión equivocada conviven sin problema. Un dato como ese necesita ir acompañado de que explica el 0.064% de la variación y de que significativo no equivale a importante, y ese acompañamiento es criterio profesional, no recuperación de información.

-
- *Tercero, un dato inmediato invita a decidir rápido.* La fricción de la cola de consultas cumplía involuntariamente una función de filtro. Al desaparecer, conviene que las decisiones de peso sigan pasando por revisión humana, sobre todo cuando el conjunto de datos tiene los vacíos: sin producto, sin costo y sin estado del pedido, hay preguntas que el agente contestará con seguridad aparente sin que la respuesta signifique lo que el usuario cree.
 - ✓ **Recomendación.** Implementarlo, con un alcance definido: como capa de autoservicio para consulta operativa y seguimiento de indicadores, no como sustituto del análisis. El costo es marginal, un modelo Flash-Lite gratuito dentro de sus límites de uso y un servidor que ya está escrito, y el retorno es directo en tiempo liberado. La condición es que el equipo mantenga las herramientas al día conforme el negocio incorpore nuevas preguntas, porque un agente conectado a doce consultas que envejecen se vuelve, con el tiempo, una fuente autorizada de respuestas incompletas.

Anexo: código y reproducibilidad

Todo el código del proyecto está versionado en el repositorio del grupo.

Estructura del repositorio

```
AgentePractica1_G5/  
├─ data/raw/           Archivo CSV original de ventas 2021  
├─ db/  
│   ├── schema.sql     Definición del esquema relacional  
│   ├── limpieza.py     Limpieza y normalización del CSV (punto 1)  
│   └─ carga.py         Carga a PostgreSQL en la nube (punto 1.d)  
├─ mcp_server/  
│   ├── database.py     Conexión de solo lectura a PostgreSQL  
│   ├── queries.py       Consultas de análisis de los puntos 2 al 6  
│   ├── server.py        Registro de las 12 herramientas MCP  
│   └─ test_server.py    Pruebas de humo del servidor  
├─ agente_adk/  
│   ├── agent.py         Agente conversacional Google ADK  
│   ├── prompt.py        Instrucciones del agente  
│   └─ validacion.py     Validación automatizada de respuestas  
├─ analisis/  
│   ├── exploratorio.py  Puntos 2 y 3 + gráficas 1 a 5  
│   ├── segmentacion.py  Puntos 4 y 5 + gráficas 6 a 9  
│   └─ distribuciones.py Gráficas 10 a 12  
├─ graficas/           Las doce visualizaciones del punto 6  
├─ docs/               Documentación fuente de este informe  
└─ informe              Consolidación de este PDF
```

1. Reproducción del análisis

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt

copy .env.example .env          # completar credenciales

python db/limpieza.py           # limpieza del CSV
python db/carga.py              # carga a PostgreSQL
python analisis/exploratorio.py # puntos 2 y 3, gráficas 1-5
python analisis/segmentacion.py # puntos 4 y 5, gráficas 6-9
python analisis/distribuciones.py # gráficas 10-12
```

2. Agente conversacional

El agente vive en un entorno virtual independiente porque google-adk requiere mcp<2 mientras que el servidor usa mcp 2.

```
python -m venv .venv-agent
.venv-agent\Scripts\pip install -r agente_adk/requirements.txt
.venv-agent\Scripts\python -m agente_adk.test_agente # prueba de humo
.venv-agent\Scripts\adk web                          # interfaz de chat
```

3. Herramientas expuestas por el MCPServer

Herramienta	Punto del alcance
obtener_estadisticas_basicas	2.b
obtener_ventas_por_mes	2.c, 3.a
obtener_distribucion_metodos_pago	2.c, 3.c
obtener_distribucion_navegadores	2.c, 3.b
obtener_uso_boletines_vales	2.c, 3.d
obtener_tendencias	3.a
obtener_segmentacion_edad	4.a
obtener_segmentacion_genero	4.b
obtener_segmentacion_boletin_vale	4.c
obtener_correlacion_venta_edad	5.a
obtener_correlacion_genero_pago	5.b
obtener_correlacion_boletin_vale	5.c

